



**UNIVERSITÀ
DEGLI STUDI
DI TRIESTE**

**Dipartimento di Scienze Economiche, Aziendali, Matematiche e
Statistiche “Bruno de Finetti”**

CORSO DI LAUREA IN SCIENZE STATISTICHE E ATTUARIALI

TESI DI LAUREA

**UN APPROCCIO STATISTICO ALLA
REPLICAZIONE SCIENTIFICA**

LAUREANDO:

Emanuele Valea

RELATORE:

Prof. Leonardo Egidi

ANNO ACCADEMICO 2025 - 2026

Al mio eroe silenzioso, mio papà

INDICE

SOMMARIO	1
INTRODUZIONE	2
OBIETTIVI DELLA TESI.....	2
STRUTTURA DELLA TESI.....	3
CAPITOLO 1: CRISI DELLA REPLICAZIONE SCIENTIFICA.....	5
1.1 DEFINIZIONI DI RIPRODUCIBILITÀ E REPLICABILITÀ.....	6
1.2 CAUSE DELLA CRISI	11
1.2.1 PRATICHE DI RICERCA DISCUTIBILI.....	11
1.2.2 PUBLICATION BIAS	13
1.2.3 CARENZE METODOLOGICHE E STATISTICHE	17
1.3 SOLUZIONI PROPOSTE PER MITIGARE LA CRISI	20
CAPITOLO 2: SUCCESSO REPLICATIVO.....	23
2.1 NOTAZIONE.....	24
2.2 PARADOSSI NELLA REPLICAZIONE	25
2.3 METODI FREQUENTISTI	25
2.3.1 STATISTICAL SIGNIFICANCE CRITERION.....	26
2.3.2 PREDICTION INTERVAL CRITERION	28
2.3.3 SMALL TELESCOPES APPROACH.....	30
2.4 METODI BAYESIANI.....	32
2.4.1 DEFAULT BAYES FACTOR	35
2.4.2 REPLICATION BAYES FACTOR	41
2.4.3 SCEPTICAL BAYES FACTOR	44
2.5 ANALISI DEI RISULTATI DEL DATASET.....	52
CAPITOLO 3: REVERSE BAYES SHRINKAGE	54
3.1 INTRODUZIONE AL NUOVO APPROCCIO.....	54
3.2 CALIBRAZIONE DEL PARAMETRO δ	58

3.2.1 DIVERGENZA DI KULLBACK-LIEBER	58
3.2.2 EMPIRICAL BAYES.....	62
3.2.3 FULL BAYES	66
3.3 APPLICAZIONE PRATICA	68
3.3.1 CALIBRAZIONE KL E EMPIRICAL BAYES	68
3.3.2 APPLICAZIONE FULL BAYES	70
3.3.3 CONFRONTO TRA I METODI.....	74
3.4 SOGLIA PER IL SUCCESSO REPLICATIVO.....	76
3.5 LIMITI DEL NUOVO APPROCCIO.....	78
3.6 POSSIBILI ESTENSIONI	79
CAPITOLO 4: REVERSE BAYES SHRINKAGE (RBS) PREDICTIVE REPLICATION	80
4.1 APPROCCIO SENZA REPLICA.....	80
4.2 APPROCCIO CON REPLICA	82
4.3 LIMITI E POSSIBILI ESTENSIONI	84
CONCLUSIONI.....	86
RINGRAZIAMENTI.....	88
BIBLIOGRAFIA.....	89

SOMMARIO

La *crisi della replicabilità* ha sollevato interrogativi sull'affidabilità di una quota consistente dei risultati pubblicati nelle scienze sperimentali, in particolare in psicologia, economia comportamentale e scienze sociali, e ha spinto la comunità statistica a sviluppare numerosi strumenti per valutare quanto i risultati di uno studio originale e della sua replica siano tra loro compatibili.

Il presente lavoro si sviluppa lungo due fronti. Da un lato, propone una rassegna critica dei principali metodi esistenti per la valutazione del successo replicativo, frequentisti e bayesiani, evidenziandone fondamenti teorici, proprietà formali e i paradossi che possono emergere nella pratica. Dall'altro, sviluppa un nuovo metodo bayesiano, fondato su un principio di *Reverse Bayes* che prende spunto da quelli già proposti in letteratura. Infatti, il nuovo metodo ricalibra direttamente lo studio originale attraverso un parametro di restringimento δ , che determina il grado di conservazione dell'effetto originariamente osservato alla luce dell'evidenza dello studio replicativo. Il parametro viene calibrato secondo tre approcci di complessità crescente, un criterio basato sulla divergenza di *Kullback-Leibler*, un approccio *Empirical Bayes* e una trattazione pienamente bayesiana, di cui vengono dimostrate le principali proprietà analitiche. Il metodo viene infine utilizzato in chiave generativa per produrre repliche simulate coerenti con il modello. Tutti i metodi discussi vengono applicati e confrontati sul dataset *RProjects*, una raccolta di 143 coppie di studi originali e relative repliche provenienti da quattro discipline.

INTRODUZIONE

La cosiddetta “*crisi della replicabilità*” rappresenta uno dei temi più discussi nell'ambito delle scienze sperimentali, in particolare della psicologia, dell'economia comportamentale e, più in generale, delle scienze sociali (Simkus *et al.*, 2025). I grandi progetti di replicazione condotti a partire dalla metà degli anni 2010 (e.g., Camerer *et al.*, 2016, 2018; Patil, Peng e Leek, 2016) hanno mostrato, con una certa consistenza, che una quota significativa dei risultati pubblicati in letteratura non trova conferma quando lo stesso studio viene riprodotto o replicato, sollevando interrogativi profondi non solo sulla validità dei singoli risultati, ma sull'intero impianto statistico ed epistemologico con cui la comunità scientifica tradizionalmente stabilisce quali risultati debbano essere considerati consolidati.

Di fronte a questo scenario, la comunità statistica ha sviluppato un ampio ventaglio di strumenti per quantificare il successo o l'insuccesso di una replicazione. Si tratta però di strumenti complementari, che permettono di valutare quanto uno studio e la sua replica siano compatibili tra loro, ma che non possono, per ovvi motivi, dirci nulla sulla verità sottostante all'effetto studiato: ogni metodo confronta due stime, entrambe soggette a incertezza campionaria, e nessuno di essi può stabilire con certezza se l'effetto esista davvero o quale sia la sua reale entità. Da questo sforzo sono nati, negli ultimi anni, criteri frequentisti relativamente semplici accanto a costruzioni bayesiane via via più sofisticate, che permettono di esprimere il grado di compatibilità tra originale e replica su una scala continua anziché attraverso un giudizio dicotomico.

OBIETTIVI DELLA TESI

Il presente lavoro si pone tre obiettivi, tra loro complementari. Il primo obiettivo, di natura ricognitiva, consiste nell'esplorare la letteratura sul tema della crisi della replicabilità e nel mettere in luce i principali dibattiti a essa collegati, con particolare attenzione ai dubbi epistemologici che tale crisi solleva, oltre che alle sue cause e alle soluzioni finora proposte.

Il secondo obiettivo, di natura essenzialmente esplorativa, consiste nel fornire una rassegna sistematica e comparata dei principali metodi disponibili in letteratura per la valutazione del successo replicativo, tanto in ambito frequentista quanto bayesiano, evidenziandone i fondamenti teorici, le proprietà formali e le relazioni reciproche.

Il terzo obiettivo, di natura propositiva, consiste nello sviluppo di un nuovo metodo bayesiano per la valutazione della replicabilità, fondato su un principio di *Reverse Bayes* diverso da quelli già presenti in letteratura, con l'intento di offrire uno strumento più facilmente interpretabile rispetto a quelli sviluppati finora. Il metodo viene infine esteso, in chiusura del lavoro, a uno strumento generativo capace di produrre repliche simulate coerenti con il modello, aprendo a possibili ulteriori applicazioni rispetto alla sola valutazione di repliche già condotte.

STRUTTURA DELLA TESI

Il presente lavoro si articola in quattro capitoli. Il Capitolo 1 introduce il fenomeno della crisi della replicabilità, ripercorrendone le cause principali, tra cui il *p-hacking*, il *publication bias* e la conseguente inflazione sistematica delle stime di effetto negli studi originali, e ne delinea l'impatto sulla pratica scientifica contemporanea, ponendo le basi motivazionali per l'intero lavoro.

Il Capitolo 2 presenta una rassegna critica dei principali metodi statistici proposti in letteratura per la valutazione del successo replicativo. Vengono dapprima discussi i criteri frequentisti per successivamente concentrarsi sui metodi bayesiani. Il capitolo si sofferma inoltre sui paradossi che possono emergere nella valutazione della replicabilità: il *replication paradox* e le due forme dello *shrinkage paradox*. Infine, si conclude con l'applicazione di tutti i metodi discussi ad un dataset di riferimento, evidenziandone il grado di concordanza e le principali fonti di discrepanza.

Il Capitolo 3 costituisce il nucleo originale della tesi: viene introdotto il nuovo metodo di restringimento bayesiano, fondato sulla ricalibrazione dello studio originale attraverso il parametro δ . Dopo averne illustrato la costruzione teorica, il capitolo sviluppa in dettaglio tre criteri di calibrazione del parametro, dimostrandone le proprietà analitiche fondamentali e discutendone il comportamento al variare dei parametri standardizzati. Il capitolo prosegue con un'ampia applicazione al dataset di riferimento, comprensiva di un'analisi di sensibilità, per poi affrontare la questione, tutt'altro che secondaria, dell'individuazione di una soglia di successo replicativo, e chiudersi con una discussione onesta dei limiti del metodo e delle sue possibili estensioni.

Il Capitolo 4 esplora un'estensione naturale del metodo sviluppato nel capitolo precedente, mostrando come lo stesso impianto teorico possa essere impiegato non solo per valutare

una replica già condotta, ma anche per generare repliche simulate, attraverso lo strumento del *Posterior Predictive Check*. Anche in questo caso, l'applicazione ad alcuni studi selezionati del dataset permette di apprezzare concretamente il funzionamento del meccanismo proposto, nonché i suoi limiti e le direzioni di sviluppo che tali limiti suggeriscono per lavori futuri.

Chiude il lavoro una sezione conclusiva, nella quale si ripercorrono sinteticamente i risultati raggiunti e si discutono, in una prospettiva più ampia, il contributo metodologico del nuovo approccio proposto e le prospettive di ricerca che da esso si aprono.

CAPITOLO 1: CRISI DELLA REPLICAZIONE SCIENTIFICA

I temi della *replicabilità* e della *riproducibilità* di un esperimento - intendendo per esperimento una prova di laboratorio o, più in generale, qualsiasi test da cui ci si attende un dato - occupano oggi una posizione di rilievo nel dibattito scientifico internazionale. Negli ultimi anni, un numero cospicuo di pubblicazioni ha messo in luce come risultati considerati consolidati siano, in svariati casi, poco affidabili e pertanto difficilmente riproducibili e replicabili (Leek e Peng, 2015). Pratiche quali il *publication bias*, il *p-hacking* e l'eccessiva flessibilità nelle analisi statistiche contribuiscono a incrementare la probabilità di risultati apparentemente significativi, ma scarsamente robusti (Simmons *et al.*, 2011). Tale constatazione ha sollevato interrogativi rilevanti non solo sul piano metodologico, ma anche sul piano epistemologico, richiamando l'attenzione sui meccanismi attraverso cui la ricerca scientifica viene condotta, validata e trasmessa (Gelman e Loken, 2014). Infatti, la difficoltà di replicare o riprodurre i risultati emerge come una conseguenza sistemica, piuttosto che come un'anomalia.

La portata del problema è tale che una larga parte della comunità scientifica ha iniziato a parlare di una vera e propria *crisi della replicazione* (Baker, 2016). L'espressione sintetizza un insieme di criticità che non possono essere ricondotte a singoli casi isolati, ma che riflette difficoltà strutturali della ricerca. In questo senso, l'incapacità di replicare o riprodurre determinati risultati non è interpretata come un fallimento occasionale, bensì come il sintomo di pratiche di ricerca e di pubblicazione che possono favorire la diffusione di evidenze fragili o sovrastimate.

Un aspetto particolarmente significativo, che merita di essere posto in primo piano, è il carattere fortemente interdisciplinare di questa crisi. Infatti, la replicabilità è un tema che attraversa numerose discipline scientifiche, accomunate da pratiche metodologiche differenti ma da problematiche analoghe in termini di affidabilità dei risultati. La letteratura ha documentato problemi di replicabilità o riproducibilità nella ricerca biomedica e clinica (Ioannidis, 2005; Begley e Ellis, 2012), nella chimica e nelle scienze sperimentali (Bergman e Danheiser, 2016), nelle scienze psicologiche (Open Science Collaboration, 2015) e nelle scienze sociali ed economiche (Camerer *et al.*, 2018). La diffusione del fenomeno in ambiti così diversi suggerisce che le sue cause non siano esclusivamente legate alle specificità di una singola disciplina, ma piuttosto a dinamiche comuni che attraversano l'intero panorama della ricerca scientifica.

La complessità del dibattito è ulteriormente accentuata dall'assenza di una definizione univoca dei concetti di replicabilità e riproducibilità, nonché di ciò che debba intendersi per una replicazione di successo (*replication success*). In molti casi, tali termini vengono impiegati in modo non coerente, con definizioni che variano a seconda del contesto disciplinare o dell'approccio metodologico adottato.

Alla luce di queste considerazioni, la replicabilità si configura come una questione che va oltre il mero aspetto tecnico-metodologico, sfociando in problemi legati all'organizzazione della ricerca, agli incentivi accademici e alla credibilità della scienza stessa. Questo primo capitolo intende pertanto offrire un inquadramento critico del dibattito sulla replicabilità, al fine di fornire le basi concettuali per le analisi sviluppate nei capitoli successivi.

1.1 DEFINIZIONI DI RIPRODUCIBILITÀ E REPLICABILITÀ

Come accennato in precedenza, un'analisi approfondita della letteratura rivela che il concetto stesso di riproducibilità manca di una definizione condivisa e universalmente accettata, configurandosi piuttosto come un costrutto complesso sensibile all'approccio adottato al problema. Come osservato da Barba (2018), questa problematica terminologica rappresenta uno degli ostacoli principali per coloro che cercano di affrontare la questione della riproducibilità scientifica.

L'assenza di un allineamento terminologico e concettuale costituisce una problematica non trascurabile, le cui radici possono essere rintracciate nell'evoluzione storica del concetto stesso di ricerca riproducibile. Una delle prime apparizioni documentate dell'espressione "*reproducible research*" in una pubblicazione scientifica risale al 1992, in un contributo presentato al convegno della *Society of Exploration Geophysics* presso l'Università di Stanford (Claerbout e Karrenbach, 1992). Claerbout, pioniere nell'uso dei computer per l'elaborazione e il filtraggio di dati, definì come "ricerca riproducibile" uno studio in cui i lettori potessero ricostruire i risultati pubblicati utilizzando i programmi e i dati grezzi dell'autore. Inoltre, Claerbout aveva già dal 1990 richiesto che le tesi di dottorato dei suoi studenti rispettassero uno standard di riproducibilità che permettesse ai colleghi di riprodurre calcoli, analisi e figure finali eseguendo un singolo comando (Barba, 2018).

L'approccio di Claerbout, approfondito ulteriormente negli anni successivi (Schwab *et al.*, 2000), mirava esplicitamente a unire una pubblicazione con la sua analisi computazionale sottostante, attraverso l'uso di strumenti di automazione e di un sistema di archiviazione

standardizzato che includesse dataset, programmi e script. Questa visione fu successivamente adottata e promossa dal professore di statistica David Donoho, anch'egli a Stanford, che nella metà degli anni '90 iniziò a diffondere questi principi. In un celebre suo lavoro (Buckheit e Donoho, 1995) compare quello che sarebbe diventato lo "slogan" della ricerca riproducibile:

“La pubblicazione di un articolo non rappresenta la ricerca stessa, ma semplicemente la sua pubblicità. La vera ricerca è costituita dall'intero ambiente di sviluppo software e dall'insieme completo di istruzioni che hanno generato i risultati presentati”

Questa tradizione pionieristica, tuttavia, non affrontava la situazione in cui un altro ricercatore potesse raccogliere nuovi dati seguendo un disegno sperimentale proprio. Fu un articolo dell'*American Journal of Epidemiology* (Peng *et al.*, 2006) a introdurre una distinzione esplicita tra questi due concetti. Peng riservò il termine "*replicazione*" per indicare scenari in cui le evidenze scientifiche vengono rafforzate attraverso studi indipendenti condotti da ricercatori diversi, che raccolgono nuovi dati utilizzando metodi analitici, laboratori e strumenti indipendenti. Definì invece con "*riproducibilità*" lo standard minimo raggiungibile, ossia la possibilità di rendere disponibili i dataset e il software utilizzati per verificare i risultati pubblicati e condurre analisi alternative, senza necessariamente dover raccogliere nuovi dati o ripetere l'intero esperimento.

Come osservato poi da Goodman *et al.* (2016), il termine "*research reproducibility*" non risulta fissato né dal punto di vista linguistico né da quello concettuale. Questa instabilità si manifesta frequentemente nell'uso intercambiabile di termini quali riproducibilità, replicabilità, ripetibilità, robustezza e affidabilità, creando ambiguità concettuali che ostacolano un dibattito rigoroso sul tema. Barba (2018) ha evidenziato come differenti comunità scientifiche utilizzino terminologie diverse per riferirsi agli stessi concetti, mentre termini apparentemente distinti vengono impiegati come sinonimi, generando confusione nella letteratura specialistica.

Un tentativo di allineamento è stato proposto da Leek e Jager (2017), i quali hanno distinto tra studio "*replicabile*" e studio "*riproducibile*". Secondo la loro definizione, uno studio è replicabile quando un esperimento identico al primo può essere condotto producendo risultati statistici consistenti, mentre è riproducibile quando tutto il codice e i dati utilizzati per generare i risultati pubblicati sono disponibili e riproducono esattamente tali risultati. Gli autori sottolineano inoltre come le definizioni di "*replication success*", ossia di

successo nella replicazione, abbiano incluso criteri differenti, quali la consistenza delle dimensioni dell'effetto, delle distribuzioni o delle misure di significatività statistica.

Una proposta classificatoria più articolata è stata sviluppata da Goodman *et al.* (2016), che hanno identificato tre dimensioni della riproducibilità:

- i. La riproducibilità *metodologica*, definita come la capacità di implementare le procedure sperimentali e computazionali nel modo più fedele possibile utilizzando gli stessi dati e strumenti per ottenere i medesimi risultati;
- ii. La riproducibilità *dei risultati*, intesa come la produzione di risultati corroboranti in un nuovo studio che abbia seguito gli stessi metodi sperimentali dell'originale;
- iii. La riproducibilità *inferenziale*, ossia la formulazione di conclusioni epistemiche di forza comparabile attraverso la replicazione o l'analisi di uno studio. Quest'ultima definizione si distingue dalla mera riproducibilità dei risultati, poiché riconosce che ricercatori diversi potrebbero trarre conclusioni differenti dagli stessi dati o compiere scelte analitiche diverse che conducono a inferenze distinte.

Una classificazione alternativa proposta recentemente (Simkus *et al.*, 2025) propone l'identificazione di cinque tipologie di riproducibilità (Tipo A-E), ciascuna caratterizzata da specifiche combinazioni di dati, metodi e conclusioni. Il Tipo A si riferisce alla capacità di seguire l'analisi di un esperimento sulla base degli stessi dati e di una descrizione chiara del metodo utilizzato. Il Tipo B contempla la riproducibilità delle conclusioni attraverso l'applicazione di metodi di analisi statistica differenti agli stessi dati. I Tipi C, D ed E introducono la dimensione dei nuovi dati: il Tipo C richiede che nuovi dati raccolti dallo stesso team di ricerca nello stesso laboratorio, utilizzando lo stesso disegno sperimentale, conducano alle medesime conclusioni; il Tipo D prevede che ciò avvenga con dati raccolti da un team diverso in un laboratorio diverso; il Tipo E, infine, richiede che le stesse conclusioni emergano da nuovi dati ottenuti attraverso disegni sperimentali o metodi di analisi differenti. Tutte queste tipologie condividono un principio fondamentale: la possibilità che le medesime conclusioni vengano raggiunte in condizioni specificate.

La situazione si è ulteriormente complicata con la diffusione di terminologie conflittuali negli anni recenti. Barba (2018) identifica nel lavoro di Drummond (2009) il punto di origine di quello che definisce uno "scambio arbitrario" della terminologia esistente. In questo contributo, l'autore invertì deliberatamente l'uso dei termini "*riproducibilità*" e "*replicabilità*" rispetto alla convenzione precedentemente introdotta da Claerbout, Donoho

e Peng, giustificando tale scelta semplicemente affermando di considerarla "ragionevole". Come osservato dal linguista Liberman (2015), data l'esistenza del termine tecnico "*reproducible research*" dal 1990 e della distinzione tra riproducibile e replicabile almeno dal 2006, tale tentativo di riconiare termini tecnici assegnandoli a concetti quasi opposti rispetto alle definizioni consolidate dovrebbe essere rigettato.

Ciononostante, questa terminologia invertita è stata adottata da numerosi autori successivi (e.g., Casadevall e Fang, 2010; Davison, 2012), che, citando esplicitamente Drummond, hanno diffuso tale uso nei campi della microbiologia e immunologia. L'adozione di questa terminologia opposta da parte di importanti organizzazioni professionali ha ulteriormente aggravato la confusione (Barba, 2018).

Per sistematizzare questa frammentazione terminologica, Barba (2018) propone un albero decisionale che classifica la letteratura in tre categorie:

- A. Gli autori che non operano alcuna distinzione tra i termini "riproducibilità" e "replicabilità" (gruppo A);
- B. Gli autori che evidenziano una distinzione tra i termini "riproducibilità" e "replicabilità" (gruppo B). Tra questi vi sono:
 - 1. Quelli che utilizzano la convenzione di Claerbout, Donoho e Peng dove "riproducibilità" indica lo standard minimo che prevede che con l'utilizzo degli stessi dati e degli stessi metodi si raggiungano gli stessi risultati (gruppo B1);
 - 2. Quelli che indicano lo standard minimo con "replicabilità", invertendo la terminologia (gruppo B2).

Un'analisi della letteratura rivela che il gruppo B1 risulta predominante, mentre il gruppo B2 comprende principalmente microbiologia, immunologia e computer science. Il gruppo A include prevalentemente scienze politiche ed economiche, dove il termine "replicazione" viene utilizzato come termine ombrello.

Diverse associazioni professionali hanno tentato di fornire chiarezza terminologica. L'*American Statistical Association* ha pubblicato nel 2017 raccomandazioni che si allineano esplicitamente con la convenzione B1, definendo la riproducibilità come la capacità di ricreare tutti i risultati numerici usando i dati originali e il codice dell'analisi, e la replicabilità come la ripetizione di un intero studio indipendentemente da quello originale senza necessariamente l'uso dei dati originali (Broman *et al.*, 2017).

Di fronte a questa complessità, alcuni autori hanno proposto terminologie espanse che tentano di catturare sfumature aggiuntive (e.g., Stodden (2015), Crook *et al.* (2013)).

In sintesi, la molteplicità di definizioni e la sovrapposizione terminologica che caratterizzano il dibattito sulla riproducibilità riflettono la complessità intrinseca del fenomeno e le diverse priorità delle varie discipline scientifiche. Come evidenziato da Barba (2018), le terminologie conflittuali costituiscono nella migliore delle ipotesi un fastidio, e nella peggiore un impedimento al progresso della scienza. Nonostante i tentativi di standardizzazione, la situazione attuale richiede che ogni lavoro scientifico definisca esplicitamente i termini utilizzati, rendendo la comunicazione interdisciplinare particolarmente complessa.

La consapevolezza di tale pluralità di definizioni costituisce pertanto un prerequisito fondamentale per qualsiasi analisi critica della crisi della riproducibilità e delle strategie proposte per affrontarla. Una soluzione a lungo termine per questo problema richiederebbe un allineamento tra le principali organizzazioni professionali, processo che appare tuttavia complesso data la diffusione delle diverse definizioni.

Alla luce di questa frammentazione terminologica, risulta necessario esplicitare quale convenzione verrà adottata nel prosieguo del presente lavoro. In considerazione della sua ampia diffusione attraverso molteplici discipline scientifiche e del suo radicamento storico nei lavori pionieristici di Claerbout, Donoho e Peng, si è scelto di aderire alla terminologia del gruppo B1. Di conseguenza, in questa tesi il termine "riproducibilità" verrà utilizzato per indicare la capacità di ricreare i risultati di uno studio utilizzando gli stessi dati e metodi computazionali resi disponibili dagli autori originali, mentre il termine "replicabilità" si riferirà alla conduzione di nuovi studi indipendenti, con la raccolta di nuovi dati, volti a verificare se le conclusioni scientifiche di un lavoro precedente possano essere confermate. Inoltre, si utilizzerà il termine "crisi di replicabilità" per indicare i problemi legati alla replicazione di uno studio, che come standard minimo dovrebbe ambire alla riproducibilità. Tale scelta metodologica, oltre a essere coerente con la letteratura prevalente nel campo, permette di mantenere la distinzione concettuale fondamentale tra la verifica dei risultati computazionali e la conferma empirica delle scoperte scientifiche attraverso studi indipendenti.

1.2 CAUSE DELLA CRISI

La crisi appena introdotta non riflette semplicemente dei problemi isolati, ma piuttosto delle carenze sistemiche nella ricerca scientifica. Come osservato da Simkus *et al.* (2025), l'impossibilità nel replicare un esperimento sollecita una riflessione sulla validità e sull'efficienza del processo di scoperta scientifica. Le cause di questa crisi sono molteplici e interconnesse, operando a livelli diversi: dalle pratiche individuali di ricerca alle strutture di incentivazione istituzionale, dalle carenze metodologiche agli incentivi editoriali. Il presente capitolo esamina queste cause, organizzandole in tre categorie principali: le pratiche di ricerca discutibili (1), il *publication bias* (2), e le carenze metodologiche e statistiche (3).

1.2.1 PRATICHE DI RICERCA DISCUTIBILI

Una delle cause centrali della crisi di replicabilità risiede in quelle che John *et al.* (2012) hanno definito "*Questionable Research Practices*", ossia pratiche di ricerca discutibili, indicate con QRPs. A differenza della frode scientifica esplicita, le pratiche di ricerca discutibili consistono in pratiche che, pur non costituendo falsificazioni deliberate, incrementano artificialmente la probabilità di ottenere risultati statisticamente significativi. Queste pratiche sono particolarmente insidiose in quanto non sono spesso riconosciute come problematiche dai ricercatori stessi, che le considerano parte legittima del processo di analisi dei dati.

Uno dei più grandi esempi di QRPs è il "*p-hacking*", ossia la pratica di selezionare come risultato (*p-value*) il valore più basso tra quelli ottenuti da molteplici test, esplorando diverse ipotesi. Questo fenomeno può facilmente condurre a risultati statisticamente significativi anche in assenza di un segnale effettivo (Laraway *et al.*, 2019).

Una pratica discutibile strettamente collegata al *p-hacking* è l'*HARKing* (*Hypothesizing After Results are Known*), termine coniato da Kerr (1998) per descrivere la pratica di presentare ipotesi formulate post-hoc, ossia dopo aver osservato i dati, come se fossero state definite a priori, ovvero prima della raccolta dei dati. Questa pratica distorce fondamentalmente la logica inferenziale sottostante ai test statistici, minando così la possibilità di replicazione dello studio stesso. Rubin (2017) differenzia diverse forme di *HARKing*:

- a) L'utilizzo di risultati ottenuti per costruire delle ipotesi *post-hoc*, presentate poi come a priori;
- b) Il recupero di ipotesi da una ricerca bibliografica condotta *post-hoc*, presentate poi come a priori;
- c) L'omissione di ipotesi a priori poiché non supportate dai risultati ottenuti.

La categoria c) si ricollega strettamente al *selective reporting*, definito da John *et al.* (2012) come la pratica di riportare solo un sottoinsieme delle analisi condotte, tipicamente quelle che producono risultati favorevoli o interessanti, omettendo analisi che non supportano le conclusioni desiderate. Il problema del *selective reporting* è particolarmente insidioso perché i lettori di un articolo pubblicato tipicamente non hanno modo di sapere cosa è stato omesso, e assumono ragionevolmente che ciò che è riportato rappresenti l'analisi completa e pianificata, impedendo così una corretta replicazione.

Un'ulteriore categoria di QRP è rappresentata dall'ambiguità intrinseca che caratterizza numerose decisioni analitiche che i ricercatori devono affrontare quotidianamente. Come sottolineato da Simmons *et al.* (2011) attraverso un'analisi di 30 articoli pubblicati in *Psychological Science*, emerge una notevole inconsistenza nelle pratiche decisionali adottate.

Infatti, il ricercatore dispone di numerosi gradi di libertà nella definizione dei dettagli dell'analisi. Questo fenomeno è stato definito da Gelman e Loken (2014) come “*garden of forking paths*” (GOFPP). Il problema risiede nel fatto che esistono innumerevoli percorsi analitici alternativi, ciascuno apparentemente giustificabile, per testare una singola ipotesi: quale trasformazione applicare ai dati, quali osservazioni escludere, quali covariate includere nel modello, come trattare i valori mancanti, e così via. Ne consegue che, una volta individuato un effetto significativo, non è detto che si sia in grado di ricostruire a ritroso il percorso che vi ha condotto. Questa inconsistenza non rappresenta necessariamente un errore metodologico in senso assoluto, in quanto ciascuna scelta fatta può essere giustificata con argomentazioni razionali e tecnicamente legittime. Tuttavia, proprio questa ambiguità costituisce terreno fertile per processi di ragionamento guidati da uno scopo (*motivated reasoning*). Come sottolineato da Kunda (1990), il *motivated reasoning* si riferisce alla tendenza cognitiva degli individui ad elaborare informazioni e prendere decisioni in modo tale da raggiungere conclusioni desiderate o coerenti con le proprie aspettative, sviluppando argomentazioni che appaiono oggettive e razionali. Nel contesto della ricerca scientifica questi processi psicologici portano i ricercatori,

inconsapevolmente, a concludere che le scelte metodologicamente appropriate siano proprio quelle che producono il risultato sperato, elaborando successivamente giustificazioni tecniche che sembrano fondate esclusivamente su considerazioni metodologiche oggettive (Simmons *et al.*, 2011).

Un'altra pratica particolarmente problematica, documentata da John, *et al.* (2012) è quella di interrompere prematuramente la raccolta dati una volta ottenuto il risultato desiderato. Sorprendentemente, un sondaggio condotto ha rivelato che circa il 70% dei ricercatori intervistati ha ammesso di aver utilizzato almeno una di queste pratiche (John, *et al.*, 2012). Simmons *et al.* (2011) dimostrano come, nonostante molti ricercatori credano che questa pratica abbia un'influenza trascurabile o nulla sul tasso di falsi positivi, la significatività dei risultati possa fluttuare considerevolmente lungo il processo di raccolta dati, attraversando ripetutamente la soglia di significatività in entrambe le direzioni.

Simonsohn *et al.* (2014) hanno sviluppato metodi statistici, noti come "*p-curve analysis*", per rilevare la presenza di queste pratiche attraverso l'analisi della distribuzione dei *p-value* in un insieme di studi. In assenza di pratiche discutibili, ci si aspetterebbe una distribuzione decrescente monotona, con concentrazione di valori molto bassi quando gli studi hanno potenza statistica adeguata e investigano effetti reali. Tuttavia, quando sono presenti QRP, la distribuzione tende a mostrare un'anomala concentrazione di *p-value* appena al di sotto della soglia convenzionale di 0.05, accompagnata da una relativa scarsità di valori appena superiori a questa soglia.

Questi risultati evidenziano come le pratiche di ricerca discutibili, pur non configurandosi come frode esplicita, possano compromettere gravemente l'attendibilità dei risultati pubblicati e contribuire significativamente alla crisi di replicabilità. La sfida principale risiede nel fatto che molte di queste pratiche operano in una zona grigia di ambiguità metodologica, dove decisioni apparentemente tecniche e legittime possono, anche inconsapevolmente, essere strumentalizzate per ottenere risultati pubblicabili, rendendo difficile distinguere tra flessibilità analitica legittima e manipolazione dei dati.

1.2.2 PUBLICATION BIAS

Oltre alle pratiche di ricerca discutibili, che riguardano la sfera individuale del ricercatore, la crisi di replicabilità è alimentata da *bias* sistemici legati al processo di pubblicazione. Il *publication bias*, definito come la tendenza sistematica delle riviste scientifiche a

pubblicare selettivamente risultati statisticamente significativi, rappresenta una distorsione strutturale che riduce drasticamente la pubblicazione di risultati negativi o nulli (Fanelli, 2012). Questa selezione alimenta un circolo vizioso che aumenta la proporzione di risultati "falsi positivi" nella letteratura pubblicata, compromettendo l'integrità e l'affidabilità della ricerca scientifica stessa (Simkus *et al.*, 2025).

Come suggerito da Johnson *et al.* (2017) gli articoli dovrebbero essere valutati e accettati in base alla qualità metodologica dell'esperimento, alla robustezza dei dati raccolti, e all'importanza teorica dell'ipotesi investigata, piuttosto che alla direzione o alla significatività statistica dei risultati ottenuti. Rimuovendo lo stigma associato ai risultati non significativi, sarebbe possibile migliorare notevolmente la riproducibilità degli studi stessi, poiché la letteratura rifletterebbe più accuratamente la vera distribuzione degli effetti (Teixeira Da Silva, 2015).

Strettamente connesso al *publication bias* è il “*file drawer problem*”. Introdotto da Rosenthal (1979), descrive la tendenza dei ricercatori a non sottoporre a revisione articoli contenenti risultati non significativi, proprio per il timore di rifiuto dovuto alle politiche editoriali che privilegiano la novità e la significatività. Questa autocensura preventiva genera una letteratura scientifica che sovrastima drammaticamente le dimensioni degli effetti reali: poiché solo i risultati statisticamente significativi vengono pubblicati, e poiché la significatività statistica richiede che la dimensione dell'effetto stimata superi una certa soglia (che dipende dalla dimensione campionaria e dalla variabilità dei dati), la letteratura pubblicata contiene sistematicamente stime inflazionate rispetto ai veri parametri.

Simonsohn *et al.* (2014) hanno quantificato rigorosamente questo fenomeno, denominato “*effect size inflation*”, dimostrando come esso abbia conseguenze profonde per la replicabilità. Infatti, i ricercatori che progettano studi di replica basandosi sulle stime pubblicate tendono inevitabilmente a sovrastimare la potenza statistica dei loro studi, conducendo repliche che falliscono nel rilevare l'effetto reale, più piccolo di quello originariamente riportato. Inoltre, quando le repliche producono stime della dimensione dell'effetto sostanzialmente minori rispetto a quelle pubblicate negli studi originali, questa discrepanza viene spesso interpretata erroneamente come fallimento della replica o come evidenza di moderatori non identificati, piuttosto che come correzione dell'inflazione iniziale.

Il problema del *publication bias* è riconosciuto da decenni, e sono stati sviluppati diversi metodi per tentare di correggerlo nelle meta-analisi. Uno dei metodi più utilizzati è il “*Trim-and-Fill*”, introdotto da Duval e Tweedie (2000). Questo metodo si basa sul presupposto che, in assenza di *bias* di pubblicazione, gli studi inclusi in una meta-analisi dovrebbero distribuirsi simmetricamente attorno alla stima media dell'effetto nel *funnel plot*, dove l'asse orizzontale rappresenta la dimensione dell'effetto stimata da ciascuno studio, mentre l'asse verticale rappresenta la precisione dello studio (solitamente misurata attraverso l'errore standard o la dimensione campionaria). Gli studi più grandi e precisi dovrebbero concentrarsi vicino alla vera dimensione dell'effetto, mentre gli studi più piccoli e meno precisi dovrebbero disperdersi più ampiamente. Quando il *publication bias* è presente, gli studi con risultati non significativi o contrari alle aspettative vengono soppressi, creando un'asimmetria nel funnel plot. Il metodo *Trim-and-Fill* tenta di correggere questa asimmetria in due passaggi sequenziali: 1) Identificazione e rimozione temporanea degli studi che si collocano nella parte più estrema dell'asimmetria (*Trim*); 2) Stima del numero di studi mancanti affinché vi sia simmetria, imputando come valori mancanti quelli speculari nel grafico (*Fill*).

Tuttavia, come dimostrato da Simonsohn *et al.* (2014), questo metodo non elimina completamente l'*effect size inflation*, ma semplicemente lo mitiga, correggendo solo parzialmente la distorsione. La ragione fondamentale di questo fallimento risiede nel fatto che il *publication bias* basato sulla significatività statistica non crea necessariamente il tipo di asimmetria che *Trim-and-Fill* presuppone. Inoltre, il metodo assume implicitamente che la fonte dell'asimmetria sia esclusivamente il *publication bias*, ignorando altre possibili cause come l'eterogeneità genuina tra studi o la presenza di bias metodologici che variano sistematicamente con la dimensione dello studio.

Il *publication bias* è ulteriormente amplificato dall'ambiente accademico caratterizzato dalla pressione del “*publish or perish*”. Questa espressione, la cui origine precisa rimane incerta ma la cui prima documentazione risale agli anni sessanta (Garfield, 1996), descrive come i ricercatori siano soggetti a intense pressioni di pubblicazione per ottenere posizioni accademiche, avanzamenti di carriera, e finanziamenti per la ricerca. Le loro *performance* sono valutate attraverso metriche quantitative, le quali non distinguono tra risultati positivi ben supportati e risultati positivi ottenuti attraverso pratiche discutibili, mentre penalizzano fortemente i risultati negativi che tipicamente non vengono pubblicati o appaiono in riviste di minor prestigio. Questo sistema di incentivi porta i ricercatori, in modo del tutto

razionale data la struttura a cui sono soggetti, a cercare di produrre risultati "pubblicabili" a tutti i costi (Fanelli, 2010).

Una conseguenza diretta e particolarmente dannosa di questi incentivi di pubblicazione è che gli studi di replicazione, che dovrebbero costituire una componente centrale del processo di validazione scientifica, sono sistematicamente scoraggiati e sottovalutati. Makel *et al.* (2012) hanno condotto un'analisi sistematica della letteratura psicologica, dimostrando che le repliche dirette costituiscono appena l'1.07% degli articoli pubblicati nelle riviste di psicologia. Questa scarsità non riflette una mancanza di valore scientifico della replicazione, ma piuttosto un allineamento razionale dei ricercatori.

Il problema è ulteriormente aggravato dal fatto che quando le repliche vengono condotte e falliscono nel confermare i risultati originali, incontrano spesso una forte resistenza alla pubblicazione. Gli autori originali possono opporsi alla pubblicazione di tali risultati, sostenendo che la replica sia metodologicamente inadeguata oppure che differenze anche minime nelle procedure sperimentali siano sufficienti a spiegare l'esito negativo. Allo stesso tempo, le riviste possono mostrarsi riluttanti a pubblicare risultati che contraddicono articoli precedentemente apparsi sulle proprie pagine, temendo controversie accademiche o potenziali danni alla propria reputazione.

Un caso emblematico è rappresentato dalla decisione di Eliot Smith, allora editor del *Journal of Personality and Social Psychology*, di rifiutare la pubblicazione di studi di replica con esito negativo relativi all'articolo di Bem (2011) apparso sullo stesso giornale. In tale occasione, Smith dichiarò esplicitamente che la rivista non avrebbe pubblicato studi di replica, indipendentemente dal fatto che essi producessero risultati positivi o negativi (Aldhous, 2011).

Questa riluttanza sistematica nei confronti della pubblicazione delle repliche genera una situazione paradossale, nella quale falsi positivi possono persistere nella letteratura scientifica per anni, se non decenni, venendo ampiamente citati e utilizzati come fondamento per ricerche successive e applicazioni pratiche. Al contrario, i tentativi di correzione empirica rimangono spesso marginali, scarsamente visibili e con un impatto limitato sullo sviluppo della conoscenza scientifica (Martin e Clarke, 2017).

Alla luce delle evidenze discusse, emerge chiaramente come il *publication bias* e gli altri meccanismi analizzati in questo paragrafo non rappresentino soltanto una distorsione retrospettiva della letteratura scientifica, ma incidano direttamente sulla possibilità stessa

di replicare i risultati pubblicati. Difatti, il fallimento delle repliche non costituisce un'anomalia inattesa, ma una conseguenza prevedibile di un sistema che filtra, amplifica e cristallizza risultati non rappresentativi dei veri effetti.

1.2.3 CARENZE METODOLOGICHE E STATISTICHE

Al di là delle pratiche discutibili e del *publication bias*, la crisi di replicabilità è alimentata da carenze metodologiche e statistiche che caratterizzano una parte della letteratura scientifica. Queste non derivano necessariamente da comportamenti inappropriati, ma da limitazioni nella comprensione statistica, vincoli pratici nella conduzione della ricerca e tradizioni disciplinari consolidate nel tempo.

Un problema persistente è rappresentato dalla potenza ridotta degli studi pubblicati. Come documentato da Button *et al.* (2013), una bassa potenza riduce la probabilità di individuare un effetto reale qualora esso esista, con conseguenze che vanno ben oltre la semplice inefficienza statistica. Le principali implicazioni includono la sovrastima sistematica delle dimensioni dell'effetto e una ridotta replicabilità dei risultati.

Quando studi con bassa potenza producono risultati statisticamente significativi, questi possono essere caratterizzati da due tipologie di errori identificate da Gelman e Carlin (2014): i "*Type M errors*", anche detti "*Magnitude Errors*", che si riferiscono alla sovrastima della dimensione dell'effetto; i "*Type S Errors*", anche detti "*Sign Errors*", che riguardano la possibilità che il segno dell'effetto stimato sia opposto al segno del vero effetto. Entrambi questi errori aumentano drasticamente al diminuire della potenza statistica dello studio.

In particolare, il *Type M Error* tende a propagarsi sistematicamente nella letteratura scientifica, creando un circolo vizioso particolarmente insidioso. Quando i ricercatori progettano nuovi studi, inclusi studi di replica, spesso basano i propri calcoli di potenza su stime di dimensione dell'effetto derivate dalla letteratura pubblicata. Se queste stime sono inflazionate, i ricercatori tendono conseguentemente a sovrastimare la potenza dei propri studi futuri. Inoltre, la grandezza dell'effetto osservato viene talvolta utilizzata come indicatore della probabilità di replicare correttamente uno studio. In questo contesto, il *Type M Error* porta anche ad una sovrastima della replicabilità attesa (Vasishth e Gelman, 2017).

Le carenze metodologiche si estendono alle scelte di progettazione, misurazione, analisi o interpretazione dei dati che introducono distorsioni sistematiche o aumentano l'incertezza dei risultati. Laraway *et al.* (2019) definiscono questi fattori come “*validity threats*”, facendo riferimento a diverse dimensioni della validità di uno studio, ciascuna delle quali può compromettere la solidità delle inferenze e, di conseguenza, la replicabilità dei risultati.

Un'ulteriore fonte di problemi che minano la replicabilità di un esperimento risiede nell'applicazione inappropriata e nella comprensione insufficiente dei metodi statistici di base. Pauli (2015) identifica una serie di problemi ricorrenti che attraversano molteplici discipline e che alimentano la crisi di replicabilità. Il problema più rilevante riguarda l'interpretazione del *p-value*, frequentemente inteso, in maniera del tutto errata, come la probabilità che l'ipotesi nulla sia vera: il *p-value* rappresenta invece la probabilità di osservare dati almeno estremi (in termini di statistica test) quanto quelli osservati, assumendo vera l'ipotesi nulla. Questa interpretazione fallace, nasce dalla confusa unione tra paradigmi statistici differenti, in particolare il miscuglio incoerente del paradigma di Fisher, che tratta il *p-value* come una misura della forza dell'evidenza contro l'ipotesi nulla, con l'approccio di Neyman-Pearson, che concepisce i test statistici come procedure decisionali dicotomiche con livelli di errore prefissati. Questa confusione porta a interpretazioni ibride problematiche.

Difatti, il *p-value* viene utilizzato in quello che Gigerenzer (2004) ha definito provocatoriamente un “*rituale*”: si rifiuta l'ipotesi nulla se il *p-value* è inferiore al valore soglia (solitamente 0.05), interpretando questo risultato come conferma della propria ipotesi alternativa, senza necessariamente averla specificata in partenza. In questo modo il *p-value* non è solo interpretato come evidenza contro l'ipotesi nulla, ma anche erroneamente come evidenza a favore dell'alternativa (Pauli, 2015). Inoltre, la dicotomizzazione o, in alcuni casi, la tricotomizzazione, di una probabilità come il *p-value* in categorie discrete (ad esempio "significativo" vs. "non significativo", oppure "altamente significativo", "significativo" e "non significativo") comporta una perdita di informazione rilevante, poiché riduce un indice continuo a una decisione binaria o ternaria che maschera l'effettiva forza dell'evidenza statistica.

Come sottolineato da Wasserstein *et al.* (2019), un problema strettamente connesso a questo uso del *p-value* come valore soglia per decisioni dicotomiche è la creazione di discontinuità artificiali, dove un risultato con *p-value* leggermente inferiore alla soglia, come 0.049, viene categorizzato come "statisticamente significativo" e quindi interpretato

come evidenza di un effetto reale, mentre un risultato con *p-value* leggermente superiore alla soglia, come 0.051, viene classificato come "non significativo" e considerato privo di valore scientifico. Questa distinzione è palesemente arbitraria dato che l'evidenza fornita dai dati è essenzialmente identica nei due casi, e la minima differenza osservata può essere facilmente manipolata variando la dimensione campionaria.

Particolarmente rilevante per il tema della replicabilità è l'interpretazione errata del *p-value* come il complemento a uno della probabilità di successo di una eventuale replicazione. Sebbene vi sia una correlazione tra queste due quantità (Senn, 2002), questa è di entità molto inferiore a quella che si può immaginare. Come dimostrato da Goodman (1992), anche con *p-value* moderatamente piccoli, la probabilità di replicazione può essere sostanzialmente più bassa delle aspettative intuitive.

La confusione tra significatività statistica e rilevanza scientifica rappresenta un ulteriore aspetto critico del problema. McCloskey e Ziliak (2007) osservano come la confusione sia da ricondurre, quantomeno nell'ambito economico, proprio a Fisher, che negli anni '20 argomentò che la significatività statistica al livello 0.05 costituisse una condizione necessaria e sufficiente per stabilire un risultato scientifico. I due autori concordano con altri critici sul fatto che la significatività statistica non è né necessaria né sufficiente per il raggiungimento della significatività scientifica. Tuttavia, sostengono che l'evidenza empirica massiccia da loro raccolta dimostri come gli economisti continuino sistematicamente a confondere i due tipi di significatività (Gelman e Stern, 2006).

Le proposte per ovviare a questi problemi legati al *p-value* sono varie. Wasserstein *et al.* (2019) propongono l'abbandono completo del concetto di significatività statistica come soglia dicotomica. Benjamin *et al.* (2017) suggeriscono invece di modificare la soglia da 0.05 a 0.005 per le nuove scoperte scientifiche. Vengono inoltre proposti approcci alternativi al classico test d'ipotesi, come il *Bayes Factor* introdotto da Goodman (1999). Tutte queste soluzioni però, anche se attuate, non risolverebbero in toto il problema della replicabilità, che richiede interventi su molteplici livelli del sistema di ricerca.

Un ulteriore problema che inficia la replicabilità è la “*molteplicità*“, che occorre quando diverse inferenze statistiche vengono considerate simultaneamente. Secondo Bretz e Westfall (2014), ignorare i problemi di molteplicità a qualsiasi stadio di uno studio potrebbe causare una mancanza di replicabilità.

A differenza delle QRP discusse nella sezione 1.2.1, che possono essere mitigate attraverso maggiore trasparenza e preregistrazione, le carenze metodologiche e statistiche richiedono interventi più profondi che includono il miglioramento dell'educazione statistica.

1.3 SOLUZIONI PROPOSTE PER MITIGARE LA CRISI

Di fronte all'evidenza crescente della crisi di replicabilità e alla comprensione approfondita delle sue cause, la comunità scientifica ha proposto diverse strategie per mitigare i problemi identificati. Queste soluzioni operano a livelli diversi, dalle pratiche individuali di ricerca alle politiche istituzionali, e vanno da interventi relativamente semplici da implementare a riforme strutturali più profonde che richiedono cambiamenti culturali sostanziali.

Simmons *et al.* (2011) hanno articolato un insieme di sei requisiti fondamentali per gli autori al fine di prevenire falsi positivi e migliorare la possibilità di riprodurre o replicare l'esperimento stesso:

- i. Il primo requisito stabilisce che i ricercatori debbano decidere la regola per terminare la raccolta dati prima che questa inizi e riportare esplicitamente tale regola nell'articolo pubblicato;
- ii. Il secondo requisito prevede che gli autori debbano raccogliere almeno 20 osservazioni per variabile utilizzata, o fornire una giustificazione convincente basata sui costi della raccolta dati se questo non è possibile;
- iii. Il terzo requisito stabilisce che gli autori elenchino nell'articolo tutte le variabili raccolte nello studio, non solo quelle incluse nell'analisi finale riportata;
- iv. Il quarto requisito richiede che gli autori riportino tutte le condizioni sperimentali, incluse le condizioni che non hanno funzionato come previsto e quelle che sono state eliminate dall'analisi finale;
- v. Il quinto requisito stabilisce che se vengono eliminate osservazioni dall'analisi (e.g., *outliers*), gli autori devono riportare anche i risultati statistici con tali osservazioni incluse, rendendo trasparente la dipendenza dei risultati dalle osservazioni escluse;
- vi. Il sesto requisito specifica che se un'analisi include una covariata, gli autori devono riportare anche i risultati dell'analisi senza la covariata, permettendo ai revisori e lettori di valutare se l'inclusione sia giustificata.

Questi requisiti potrebbero essere implementati attraverso un modulo standard compilato, (*pre-registration*) al momento della pubblicazione, analogamente ai moduli per conflitti di interesse o approvazione etica. Complementari ai requisiti per gli autori, Simmons *et al.* (2011) propongono quattro linee guida per revisori che possono aiutare a identificare e prevenire la pubblicazione di falsi positivi:

- i. La prima linea guida stabilisce che i revisori dovrebbero assicurare che gli autori seguano i requisiti sopra elencati;
- ii. La seconda linea guida suggerisce che i revisori dovrebbero essere più tolleranti verso imperfezioni e complessità nei risultati quando questi sono riportati trasparentemente;
- iii. La terza linea guida richiede che i revisori possano richiedere agli autori di dimostrare che i loro risultati non dipendono in maniera cruciale da decisioni arbitrarie, richiedendo analisi di robustezza che mostrano che le conclusioni rimangono stabili sotto alternative ragionevoli per decisioni ambigue;
- iv. La quarta linea guida stabilisce che se le giustificazioni per le dimensioni campionarie, le regole di esclusione, o le scelte analitiche non sono convincenti, i revisori dovrebbero poter richiedere agli autori di condurre una riproduzione esatta dello studio prima dell'accettazione.

Gli autori notano che questi suggerimenti per i revisori, relativamente diffusi in epoche precedenti, sono attualmente difficili da attuare per via delle pressioni relative al processo di pubblicazione, già discusse in precedenza.

Un'ulteriore proposta atta a garantire la riproducibilità e replicabilità di un esperimento è la preregistrazione degli studi, ossia la richiesta che il disegno sperimentale, le ipotesi, e il piano di analisi vengano depositati in un registro pubblico prima della raccolta dati stessi. La preregistrazione elimina la tentazione di cercare attraverso molteplici percorsi analitici fino a trovarne uno che conduce alla significatività statistica (Nosek *et al.*, 2022).

Come visto in precedenza, una soluzione che potrebbe migliorare la replicabilità è l'abbandono del concetto di significatività statistica (Wasserstein *et al.*, 2019). Questo però, incontrerebbe una forte resistenza della comunità scientifica, vista la sua notevole diffusione e la facile interpretazione come scelta dicotomica. La posizione potrebbe essere mitigata pensando al *p-value* come un indicatore di evidenza tra molti e non come unico parametro della presenza o assenza di un effetto.

Come sottolineato da Leek *et al.* (2017), il problema non risiede nella matematica alla base dei metodi statistici, ma nel modo in cui questi vengono applicati e interpretati dagli esseri umani. Difatti, l'analisi dei dati non è puramente computazionale, bensì è un comportamento umano. Inoltre, l'applicazione della statistica varia enormemente da campo a campo e nessun approccio individuale potrà mai risolvere la crisi della replicabilità. La sfida deve essere raccolta dai finanziatori e dalle riviste, oltre che dai singoli ricercatori.

CAPITOLO 2: SUCCESSO REPLICATIVO

Dopo aver introdotto la crisi della replicabilità, le sue potenziali cause e alcune possibili soluzioni, l'attenzione si sposta ora sugli strumenti statistici utilizzati per determinare se uno studio di replicazione possa essere considerato riuscito.

Come discusso in precedenza, non esiste una definizione univoca di *replication success*. Tale concetto, infatti, dipende sia dal quadro teorico di riferimento sia dalle scelte metodologiche del ricercatore. A monte di questa eterogeneità vi è, del resto, un limite di natura più radicale: salvo rari casi (e.g., simulazioni), non è possibile conoscere la verità sottostante dell'esperimento, ovvero se l'effetto oggetto di studio esista realmente e quale sia la sua entità. Il successo replicativo non può quindi mai essere affermato in senso assoluto, ma solo stimato sulla base di criteri statistici che ne approssimano la valutazione, ciascuno fondato su assunzioni proprie circa cosa costituisca evidenza sufficiente a favore della replica. Diverse tradizioni statistiche propongono criteri differenti, spesso fondati su assunzioni epistemologiche distinte. Alla luce tutto ciò, si è ritenuto opportuno analizzare e confrontare alcuni dei metodi più diffusi, distinguendoli in due macro-categorie: approcci frequentisti e approcci *bayesiani*.

Al fine di garantire un confronto tra i diversi metodi, si è deciso di applicarli utilizzando il dataset “*RProjects*”, reso disponibile nel pacchetto *R* “*ReplicationSuccess*” (Held, 2025), il quale contiene 143 studi replicati con i rispettivi risultati originali, raccogliendo dati provenienti da quattro tra i più importanti progetti di replicazione su larga scala:

- Il *Reproducibility Project: Psychology* (RPP) (Open Science Collaboration, 2015), di cui sono incluse le 73 coppie di studi (sulle 100 originarie) per le quali è disponibile l'errore standard della correlazione trasformata secondo Fisher;
- L'*Experimental Economics Replication Project* (EERP) (Camerer *et al.*, 2016);
- Il *Social Sciences Replication Project* (SSRP) (Camerer *et al.*, 2018);
- L'*Experimental Philosophy Replicability Project* (EPRP) (Cova *et al.*, 2021) di cui sono incluse 31 coppie di studi (sulle 40 originarie) per le quali è disponibile simultaneamente la dimensione campionaria effettiva dello studio originale e di quello replicato.

Per ciascuna coppia di studi, il dataset riporta le stime dell'effetto, espresse sia sulla scala della correlazione sia, previa trasformazione, sulla scala di *Fisher-z*, unitamente ai rispettivi errori standard, alle dimensioni campionarie e ai *p-value* (calcolati sia in versione a due

code sia, nella direzione dell'effetto originale, in versione a una coda), secondo un'impostazione comune adottata per tutti i progetti considerati. Per un sottoinsieme di studi provenienti da EERP e SSRP è inoltre disponibile una misura della credenza a priori circa l'esito della replicazione, elicitata attraverso un mercato predittivo (*prediction market*).

È opportuno precisare che, nel dataset *RProjects*, gli effetti di interesse sono rappresentati da coefficienti di correlazione, pertanto compresi nell'intervallo $[-1,1]$. La sua struttura e la sua diffusione rende *RProjects* particolarmente adatto all'obiettivo del presente capitolo, consentendo l'applicazione coerente di molteplici criteri di valutazione del *replication success*.

Inoltre, il dataset è stato ampiamente utilizzato nella letteratura recente sul tema, inclusi degli studi citati in precedenza (e.g., Open Science Collaboration, 2015; Camerer *et al.*, 2018; Held, 2020; Pawel e Held, 2022; Consonni e Egidi, 2025), configurandosi come un riferimento empirico consolidato per lo studio della replicabilità.

2.1 NOTAZIONE

Al fine di garantire di garantire chiarezza espositiva e coerenza formale nella presentazione dei criteri di valutazione del *replication success*, si introduce di seguito la notazione che verrà adottata nel resto del capitolo e oltre. Tale formalizzazione consente di descrivere in modo compatto e unificato sia gli studi originali sia le relative replicazioni, facilitando il confronto tra i diversi metodi di valutazione considerati.

Sia $k \in \{o, r\}$ un indice che identifica il tipo di studio, dove o denota lo studio originale e r denota lo studio di replicazione. Dato l'effetto di interesse θ , con spazio parametrico Θ , per ciascun studio k si definiscono:

- $\hat{\theta}_k$ la stima puntuale dell'effetto di interesse;
- σ_k^2 la varianza dell'effetto;
- $z_k = \hat{\theta}_k / \sigma_k$ lo *z-value* corrispondente;
- p_k il *p-value* associato all'ipotesi nulla $H_0: \theta = 0$;
- n_k la numerosità campionaria dello studio;
- y_k le osservazioni dello studio.

Qualora necessario, verranno introdotte ulteriori quantità utili all'analisi.

2.2 PARADOSSI NELLA REPLICAZIONE

Prima di procedere alla descrizione dettagliata di alcuni dei diversi metodi per valutare il successo replicativo, è opportuno discutere alcuni paradossi a cui sono soggette le misure che andremo ad introdurre, unici al contesto della replicazione (Pawel e Held, 2022):

- *Replication paradox*: discusso da Ly *et al.* (2019), si verifica quando le stime dell'effetto negli studi originale e replicato hanno direzioni opposte (i.e., $\text{sign}(\hat{\theta}_r) \neq \text{sign}(\hat{\theta}_o)$), ma il metodo di valutazione scelto segnala comunque il successo replicativo.

Alcuni metodi, come vedremo, evitano strutturalmente questo paradosso (e.g., *statistical significance criterion*) mentre altri possono, in linea di principio, dichiarare un successo di replicazione anche in caso di effetti discordi (e.g., *Replication Bayes Factor*, *Sceptical Bayes Factor*).

Nella pratica questo paradosso è però poco comune, visto che difficilmente uno studio di replicazione porta un risultato contraddittorio in termini di direzione dell'effetto, ma va comunque tenuto a mente nell'analisi dei metodi che verrà svolta;

- *Shrinkage Paradox*: si verifica quando il metodo di valutazione scelto dichiara successo replicativo per stime dell'effetto dello studio replicato relativamente piccole rispetto a quelle dello studio originale (i.e., $\hat{\theta}_r/\hat{\theta}_o \downarrow 0$).

Questo paradosso può essere dovuto alla precisione dello studio replicato (i.e., $\sigma_o^2/\sigma_r^2 \rightarrow \infty$) o alla evidenza dello studio originale (i.e., $z_o^2 \rightarrow \infty$).

Nella pratica questo paradosso è più comune del precedente. Anche in questo caso, esistono misure che evitano questo paradosso (e.g., *Sceptical Bayes Factor*,) ed altre che invece ne sono più soggette (e.g., *Replication Bayes Factor*).

Per valutare quindi la bontà dei metodi proposti, può essere utile tenere a mente questi paradossi e valutare se il metodo in analisi ne è soggetto.

2.3 METODI FREQUENTISTI

La prima famiglia di criteri per la valutazione del successo replicativo qui esaminata si colloca all'interno del framework statistico frequentista, fondato sulla logica del *Null Hypothesis Significance Testing* (NHST) (Pauli, 2015).

Nel contesto della replicazione, il framework frequentista si traduce in una serie di criteri che, pur condividendo il medesimo fondamento inferenziale, differiscono sensibilmente per la domanda a cui intendono rispondere e per le assunzioni su cui si basano. Alcuni si concentrano sull'esito del test di significatività nella replica, altri sulla compatibilità tra le stime degli effetti, altri ancora sulla capacità informativa del disegno originale. Questa eterogeneità riflette la mancanza di una definizione univoca di *replication success* e la pluralità di prospettive attraverso cui il concetto può essere analizzato.

È opportuno sottolineare che i metodi frequentisti per la valutazione della replicabilità ereditano, inevitabilmente, le criticità strutturali del framework su cui si fondano. In particolare, la dipendenza dalla soglia arbitraria $p < 0.05$ e la sua natura dicotomica, rappresentano limitazioni che nessuno dei criteri frequentisti è in grado di superare completamente. Ciò nonostante, tali metodi mantengono una rilevanza pratica considerevole, sia per la loro semplicità interpretativa sia per la loro ampia diffusione nella letteratura sulla replicabilità.

Nelle sezioni seguenti vengono presentati e applicati al dataset *RProjects* tre criteri frequentisti di crescente complessità concettuale. Il primo, lo *statistical significance criterion*, rappresenta l'approccio più diretto e intuitivo, fondato sulla sola significatività statistica della replica. Il secondo, il *prediction interval criterion*, sposta l'attenzione dalla significatività alla compatibilità tra le stime, incorporando esplicitamente l'incertezza associata a entrambi gli studi. Il terzo, lo *Small Telescopes Approach*, adotta una prospettiva radicalmente diversa, valutando non l'esito della replica bensì l'adeguatezza del disegno sperimentale dello studio originale alla luce dei risultati della replicazione.

2.3.1 STATISTICAL SIGNIFICANCE CRITERION

Il primo metodo considerato è lo *statistical significance criterion*, così denominato da Camerer *et al.* (2018). Tale criterio rappresenta uno degli approcci più intuitivi e facilmente applicabili per valutare il successo di una replicazione, in quanto si fonda su una logica dicotomica semplice e di agevole interpretazione. Secondo questo criterio, una replicazione può essere considerata di successo qualora soddisfi simultaneamente due condizioni:

- (i). L'effetto osservato nello studio di replicazione risulta statisticamente significativo;
- (ii). La direzione dell'effetto sia coerente con quella osservata nello studio originale.

È importante sottolineare come questo criterio sia applicabile esclusivamente agli studi originali che abbiano riportato un risultato statisticamente significativo. Formalmente, assumendo che lo studio originale soddisfi la condizione di significatività statistica (i.e., $p_o < 0.05$), il successo replicativo secondo il *statistical significance criterion* è definito dalla seguente condizione:

$$\{p_r < 0.05\} \wedge \{\text{sign}(\hat{\theta}_r) = \text{sign}(\hat{\theta}_o)\}$$

dove $\text{sign}(\cdot)$ indica il segno della stima dell'effetto.

Applicando tale criterio al dataset *RProjects*, si osserva che, dei 143 studi, 132 studi originali risultano statisticamente significativi e sono pertanto eleggibili. Tra questi, circa il 51% delle repliche (67 su 132) soddisfa il criterio, mentre il restante 49% (65 su 132) non soddisfa le condizioni per il successo di replicazione.

Nonostante la sua immediatezza operativa, questo criterio presenta diverse limitazioni concettuali e metodologiche. In primo luogo, la valutazione del successo replicativo viene ridotta a una decisione dicotomica, trascurando le sfumature del concetto di replicabilità stessa. In secondo luogo, il criterio eredita tutte le criticità associate all'uso dei *p-value*, già discusse in precedenza, e alla distinzione rigida tra risultati “statisticamente significativi” e “non significativi” (Gelman e Stern, 2006). Inoltre, non vengono considerate direttamente né la magnitudine dell'effetto né la precisione delle stime, se non in maniera implicita attraverso il *p-value*.

Una possibile estensione di questo criterio consiste nell'utilizzare, al posto della sola replica, una stima meta-analitica dell'effetto, che combini le stime dello studio originale e della replicazione (e.g., Camerer *et al.*, 2018; Muradchanian *et al.*, 2024).

Formalmente:

$$\hat{\theta}_{meta} = \frac{\hat{\theta}_o \frac{1}{\sigma_o^2} + \hat{\theta}_r \frac{1}{\sigma_r^2}}{\frac{1}{\sigma_o^2} + \frac{1}{\sigma_r^2}}, \quad \sigma_{meta}^2 = \frac{1}{\frac{1}{\sigma_o^2} + \frac{1}{\sigma_r^2}}$$

Assumendo la normalità dell'effetto meta-analitico, è immediato calcolare il *p-value* relativo all'ipotesi di nullità dell'effetto e verificare il successo di replicazione mediante la seguente condizione:

$$\{p_{meta} < 0.05\} \wedge \{\text{sign}(\hat{\theta}_{meta}) = \text{sign}(\hat{\theta}_o)\}$$

Utilizzando questo approccio, si osserva che circa il 77% delle repliche (102 su 132) del dataset in analisi soddisfa il criterio, mentre il restante 23% (30 su 132) non soddisfa le condizioni di successo. Questo aumento rispetto al 51% osservato con il criterio basato solo sulla replica è dovuto al fatto che la stima originale, se relativamente grande o inflazionata (per tutte le motivazioni precedentemente approfondite), tende a spingere il meta-effetto verso l'effetto originale, rendendo più probabile che $p_{meta} < 0.05$ (Camerer *et al.*, 2018) e che quindi vi sia successo di replicazione.

Per mitigare questo ottimismo nelle stime, Camerer *et al.* (2018) propongono di abbassare la soglia da 0.05 a 0.005, coerentemente con quanto suggerito da Benjamin *et al.* (2017) per le nuove scoperte scientifiche. Con questa soglia più stringente, circa il 61% delle repliche (81 su 132) soddisfa il criterio, mentre il restante 39% (51 su 132) non raggiunge il successo di replicazione.

In conclusione, sebbene il *statistical significance criterion* e la sua versione meta-analitica siano intuitivi e di facile applicazione, le limitazioni sopra descritte ne impediscono l'uso come unico criterio di valutazione. Per ottenere una stima più completa e affidabile della replicabilità, è necessario affiancare questi approcci ad altri criteri che considerino i suoi limiti.

2.3.2 PREDICTION INTERVAL CRITERION

Un criterio complementare al precedente è quello che indicheremo con *prediction interval criterion*, definito da Patil *et al.* (2016). Questo approccio valuta il successo di una replicazione verificando se la stima dell'effetto ottenuta nello studio replicativo appartenga all'intervallo di previsione costruito in base alla stima dell'effetto ottenuta nello studio originale e la variabilità dei due studi.

Al fine di costruire questo intervallo, gli effetti vengono espressi sulla scala Fisher-z, ottenuta applicando la trasformazione di Fisher alle stime di correlazione come segue:

$$\hat{z}_k = \frac{1}{2} \ln \left(\frac{1 + \hat{\theta}_k}{1 - \hat{\theta}_k} \right), \quad k \in \{o, r\}$$

L'utilizzo di tale scala è motivato da ragioni di natura computazionale. Le correlazioni, infatti, sono vincolate all'intervallo $[-1, 1]$ e presentano una distribuzione asimmetrica. La trasformazione di Fisher consente di mappare le correlazioni su una scala non limitata,

producendo una variabile che, sotto ipotesi standard, è approssimativamente normale con varianza pari a $1/(n_k - 3)$, con $k \in \{o, r\}$. Questa proprietà rende la scala Fisher-z particolarmente adatta per procedure inferenziali, garantendo una trattazione più semplice ma comunque teoricamente fondata.

Nel caso specifico del *prediction interval criterion*, l'assunzione di normalità risulta cruciale per la validità dell'intervallo predittivo. Sulla scala Fisher-z, l'intervallo predittivo al 95% è formalmente definito come:

$$IC_{95\%} = \hat{\theta}_o \pm z_{0.975} \sqrt{\frac{1}{n_o - 3} + \frac{1}{n_r - 3}}$$

dove $z_{0.975}$ è il quantile al 97.5% di una normale standard. Il successo di replicazione è quindi stabilito dalla condizione:

$$\hat{\theta}_r \in IC_{95\%}$$

A differenza del criterio precedente, questo metodo non si fonda sui *p-value* e non richiede che lo studio originale sia statisticamente significativo. La valutazione si basa esclusivamente sulla compatibilità tra la stima replicata e la distribuzione predittiva derivata dall'effetto originale, incorporando esplicitamente l'incertezza associata ad entrambi gli studi.

Applicando questo criterio al dataset *RProjects*, si osserva che, dei 143 studi considerati, circa il 38% delle replicazioni (55 su 143) soddisfa il criterio, mentre il restante 62% (88 su 143) non soddisfa le condizioni per il successo di replicazione. Limitando l'analisi ai soli studi con effetto originale significativo, la percentuale di successi risulta pari a circa il 37% (49 su 132), indicando come la restrizione agli studi significativi non modifichi sostanzialmente il quadro complessivo.

Il confronto con il *statistical significance criterion* evidenzia differenze sostanziali. Mentre quest'ultimo classificava come repliche di successo circa il 51% degli studi, il *prediction interval criterion* conduce a una stima significativamente più conservativa.

In questo senso, il *prediction interval criterion* può essere interpretato come un criterio più stringente, poiché richiede che la stima replicata sia plausibile con quella originale, alla luce dell'incertezza degli studi, indipendentemente dal raggiungimento della significatività statistica.

Nonostante i vantaggi concettuali, anche questo criterio presenta alcune limitazioni. In particolare, la valutazione rimane di natura dicotomica e l'ampiezza dell'intervallo dipende dall'accuratezza delle stime di varianza. Inoltre, eventuali fenomeni di inflazione dell'effetto nello studio originale possono condizionare la posizione, influenzando la classificazione delle repliche.

2.3.3 SMALL TELESCOPES APPROACH

Un criterio alternativo per la valutazione del successo replicativo è rappresentato dallo *Small Telescopes Approach*, proposto da Simonsohn (2015). A differenza dei criteri tradizionali basati sulla significatività statistica, questo metodo non si concentra direttamente sull'esito della replica, ma sulla capacità informativa dello studio originale.

L'intuizione centrale del criterio è efficacemente illustrata attraverso un'analogia astronomica. Si consideri un astronomo che affermi di aver scoperto un nuovo pianeta mediante un telescopio di modeste dimensioni. Un secondo astronomo, tentando di verificare la scoperta, impiega un telescopio più potente, non rilevando però alcun corpo celeste. Tale esito non dimostra necessariamente l'inesistenza del pianeta, ma mette in discussione la plausibilità dell'osservazione originale. Infatti, un segnale sufficientemente intenso da essere rilevato da uno strumento meno potente dovrebbe risultare osservabile a maggior ragione mediante uno strumento più sensibile.

Trasferendo questa logica al contesto della replicazione, lo studio originale può essere interpretato come un "piccolo telescopio", tipicamente caratterizzato da una numerosità campionaria ridotta e quindi da una ridotta capacità di rilevare effetti di piccola quantità, mentre la replica rappresenta un "telescopio grande", generalmente dotato di maggiore precisione. In questa prospettiva, la questione rilevante non è tanto se la replica abbia prodotto un risultato significativo, quanto piuttosto se l'effetto osservato nella replica sia così piccolo da risultare non rilevabile con il disegno sperimentale dello studio originale.

Formalmente, si definisce $d_{33\%}$ la dimensione dell'effetto che conferirebbe allo studio originale una potenza statistica del 33% per un test di significatività al livello $\alpha = 0.05$. La scelta di questa soglia non è arbitraria: una potenza del 33% implica che la probabilità di non rilevare alcun effetto nella replica è doppia rispetto a quella di rilevarlo, configurando uno scenario di *severe underpowering* (Simonsohn *et al.*, 2014). Pertanto, effetti di magnitudo inferiore a $d_{33\%}$ risulterebbero troppo piccoli per essere stati plausibilmente

identificati dallo studio originale. Quindi, una volta determinata la soglia $d_{33\%}$, si verifica se l'effetto stimato nella replica sia significativamente inferiore alla soglia attraverso il seguente test di ipotesi:

$$H_0: \theta = d_{33\%}, \quad H_1: \theta < d_{33\%}$$

Una replica è considerata di successo se la stima dell'effetto della replica non è significativamente inferiore del valore soglia $d_{33\%}$.

Un presupposto fondamentale dello *Small Telescopes Approach* è che la replica disponga di una numerosità campionaria superiore a quella dello studio originale. A tal proposito, Simonsohn (2015) dimostra come, per avere circa l'80% di potenza statistica nel rigettare l'ipotesi nulla quando l'effetto vero è zero, la replica dovrebbe disporre di almeno 2.5 volte la numerosità campionaria dello studio originale. Questa regola si applica in modo generalizzato, indipendentemente dal tipo di test statistico o dal disegno sperimentale.

Prima di applicare il metodo al dataset *RProjects*, si è quindi ritenuto opportuno verificare in quale misura gli studi di replica rispettassero tali requisiti. L'analisi ha rivelato che solamente il 72% degli studi replicati (103 su 143) presenta effettivamente una numerosità campionaria maggiore rispetto allo studio originale. Di questi 103 studi, soltanto 33 (32%) soddisfano la condizione più stringente suggerita da Simonsohn ($n_r \geq 2.5 \times n_o$). Questo suggerisce che una quota non trascurabile delle repliche nel dataset potrebbe non disporre della potenza statistica necessaria per applicare in modo ottimale lo *Small Telescopes Approach*.

Applicando comunque il criterio all'intero dataset, si osserva che, dei 143 studi considerati, circa il 26% delle repliche (37 su 143) soddisfa il criterio di successo, mentre il restante 74% (106 su 143) non lo soddisfa. Questo tasso di successo risulta considerevolmente inferiore rispetto ai criteri precedentemente discussi, rendendo lo *Small Telescopes Approach* il metodo più selettivo tra quelli esaminati.

Restringendo l'analisi ai soli studi di replicazione con numerosità maggiore dell'originale ($n_r > n_o$), circa il 33% delle repliche (34 su 103) soddisfa il criterio. Limitando ulteriormente il dataset alle repliche che soddisfano la condizione $n_r \geq 2.5 \times n_o$, la percentuale di successo aumenta al 45% (15 su 33). Questo incremento progressivo è coerente con la logica sottostante al metodo.

In conclusione, sebbene lo *Small Telescopes Approach* presenti vantaggi metodologici rilevanti esso risulta caratterizzato da una minore immediatezza interpretativa rispetto ai criteri precedentemente discussi.

In primo luogo, si richiede la comprensione non del tutto intuitiva del concetto di $d_{33\%}$ e di come questo sia collegato alla replicazione. In secondo luogo, l'interpretazione dei risultati è più sfumata: non si può concludere la presenza o assenza di un effetto, bensì che lo studio originale dispone o non dispone degli strumenti statistici adeguati a studiarlo. Questa conclusione, pur statisticamente rigorosa, può risultare meno definitiva e quindi meno soddisfacente dal punto di vista della comunicazione scientifica rispetto a un'affermazione più diretta sulla replicabilità.

Infine, l'applicazione del metodo presuppone che le repliche dispongano di numerosità campionarie sostanzialmente maggiori rispetto agli originali, una condizione che, come emerso dall'analisi, non sempre si verifica nella pratica. Quando tale requisito non è soddisfatto, l'interpretazione dei risultati diventa ulteriormente problematica, poiché anche la replica potrebbe non disporre di potenza sufficiente per valutare la validità dello studio originale.

2.4 METODI BAYESIANI

Come discusso nella sezione precedente, i metodi frequentisti presentano limiti strutturali intrinseci al loro framework. Nonostante tali problematiche siano ormai ampiamente riconosciute nella comunità scientifica (Gelman e Loken, 2014), non vi è una direzione precisa sul come affrontarle (Wasserstein e Lazar, 2016).

In questo panorama, colpisce la relativa scarsità di alternative fondate sull'approccio bayesiano, considerato il suo fondamento epistemologico flessibile e la natura diretta dei suoi output (Wagenmakers *et al.*, 2008). L'adozione dei metodi bayesiani continua a essere ostacolata da diversi fattori, tra cui la convinzione che strumenti computazionali avanzati siano necessari per renderli praticabili (Green *et al.*, 2015).

L'ostacolo più persistente rimane tuttavia la necessità di specificare una distribuzione a priori sull'effetto di interesse, anche in assenza di informazioni adeguate su cui basarla. Questo problema ha limitato la diffusione dei metodi bayesiani sin dalla loro comparsa e ha generato una varietà di approcci parziali, ciascuno con i propri sostenitori e critici (Held *et al.*, 2021).

Tra le risposte a questo problema, una delle meno approfondite fu proposta da Good (1950), uno dei più influenti sostenitori dei metodi bayesiani del Novecento e successivamente applicata al contesto della replicazione da Held (2020). Good riconobbe che in molte situazioni non esiste una scelta ovvia per le distribuzioni a priori, mentre spesso siamo certi di quali inferenze a posteriori ci convincerebbero della credibilità di un'ipotesi. Per questa ragione, propose di invertire il teorema di Bayes: anziché partire da una a priori per derivare la a posteriori, si parte da un a posteriori desiderata e si risale alla a priori che, combinata con i dati osservati, condurrebbe a tale conclusione, il cosiddetto “*Reverse Bayes*”.

Per comprendere questa intuizione, si considerino due ipotesi in competizione H_1, H_2 e il teorema di Bayes espresso in termini di *odds*:

$$\frac{p(H_1|\text{dati})}{p(H_2|\text{dati})} = \frac{p(\text{dati}|H_1)}{p(\text{dati}|H_2)} \times \frac{p(H_1)}{p(H_2)}$$

dove le *odds* a posteriori sono espresse come prodotto tra le *odds* della verosimiglianza e le *odds* a priori. L'approccio bayesiano standard, denominato *Forward Bayes*, fissa le *odds* a priori e calcola le *odds* a posteriori. Il *Reverse Bayes* ribalta questa logica, determinando le *odds* a priori necessarie a partire da un'inferenza a posteriori desiderata e dai dati osservati:

$$\frac{p(H_1)}{p(H_2)} = \frac{p(H_1|\text{data})}{p(H_2|\text{data})} / \frac{p(\text{data}|H_1)}{p(\text{data}|H_2)}$$

Good sottolineò che, filosoficamente, non vi è nulla di scorretto nelle inferenze derivanti dall'uso inverso del teorema di Bayes, poiché quest'ultimo si limita a vincolare a priori e a posteriori affinché siano consistenti con gli assiomi del calcolo delle probabilità, indipendentemente dall'ordinamento temporale convenzionalmente suggerito dalla loro nomenclatura.

La maggior parte degli approcci *Reverse Bayes* sviluppati successivamente utilizza questa inversione per mettere alla prova o corroborare la credibilità di affermazioni scientifiche: si specifica un'inferenza a posteriori corrispondente alla credibilità o meno di un risultato, si deriva la a priori tramite l'inversione del teorema di Bayes e si valuta se tale a priori sia plausibile alla luce delle conoscenze esistenti. È evidente come questo schema si adatti naturalmente al contesto della replicazione, in cui i dati di uno studio replicativo rappresentano un candidato naturale per valutare la plausibilità della a priori implicata dallo studio originale.

I metodi bayesiani presentati nelle sezioni seguenti si fondano sia sull'approccio *Forward Bayes*, che sull'approccio *Reverse Bayes*, declinandoli in strumenti operativi di crescente complessità per la valutazione del successo replicativo.

Tutti i metodi bayesiani presentati nelle sezioni seguenti si fondano sulla nozione di *Bayes Factor*, che costituisce lo strumento operativo comune attraverso cui sia l'approccio *Forward* che il *Reverse Bayes* vengono declinati nel contesto della replicazione.

Introdotta per la prima volta da Jeffreys nel 1961 e successivamente schematizzata da Kass e Raftery (1995), il *Bayes Factor* quantifica la forza dell'evidenza empirica a favore di un'ipotesi rispetto a un'altra.

Formalmente, siano H_1 e H_2 due modelli bayesiani per una stessa variabile osservabile y :

$$H_j: \{f(y|\theta_j, H_j); f(\theta_j|H_j)\}, \quad j = 1, 2$$

Il *Bayes Factor* a favore di H_1 rispetto ad H_2 , osservati i dati y , è definito come:

$$BF_{1:2}(y) \stackrel{\text{def}}{=} \frac{f(y|H_1)}{f(y|H_2)} = \frac{\int_{\Theta_1} f(y|\theta_1, H_1) f(\theta_1|H_1) d\theta_1}{\int_{\Theta_2} f(y|\theta_2, H_2) f(\theta_2|H_2) d\theta_2}$$

dove $f(y|H_i)$ è la verosimiglianza marginale di y sotto H_i , nota anche come verosimiglianza marginale di H_i , ottenuta integrando la verosimiglianza $f(y|\theta_i, H_i)$ rispetto alla distribuzione a priori $f(\theta_i|H_i)$ sui parametri $\theta_i \in \Theta_i$ del modello i -esimo, con $i = 1, 2$.

Il *Bayes Factor* può essere interpretato come il fattore per cui le *odds* a priori devono essere moltiplicate per ottenere le *odds* a posteriori, in accordo con la formulazione del teorema di Bayes in termini di rapporti, come visto in precedenza:

$$\frac{p(H_1|y)}{p(H_2|y)} = \frac{p(y|H_1)}{p(y|H_2)} \times \frac{p(H_1)}{p(H_2)} = BF_{1:2}(y) \times \frac{p(H_1)}{p(H_2)}$$

L'interpretazione del *Bayes Factor* è intuitiva: un valore maggiore di $BF_{1:2}(y) > 1$ indica che i dati sono più plausibili sotto H_1 che sotto H_2 ; un valore minore di 1 indica invece che i dati sono più plausibili sotto H_2 che sotto H_1 . Inoltre, è opportuno precisare che:

$$BF_{1:2}(y) = \frac{1}{BF_{2:1}(y)}$$

Pertanto, il *Bayes Factor* può essere ugualmente impiegato per quantificare l'evidenza a favore dell'ipotesi H_2 rispetto all'ipotesi H_1 . La scelta di quale ipotesi porre al numeratore

è convenzionale e dipende dal contesto applicativo: ciò che conta è l'interpretazione coerente del rapporto risultante.

$BF_{1:2}(y)$	$2 \log(BF_{1:2}(y))$	Interpretazione
1 – 3	0 – 2	Evidenza debole per H_1
3 – 20	2 – 6	Evidenza moderata per H_1
20 – 150	6 – 10	Evidenza forte per H_1
> 150	> 10	Evidenza molto forte per H_1

Tabella 1: scala interpretativa Bayes Factor

La scala interpretativa per $BF_{1:2}$ proposta da Kass e Raftery (1995), riportata nella Tabella 1, è espressa anche in termini di $\log(BF_{1:2})$, in quanto questa trasformazione colloca il Bayes Factor sulla stessa scala della devianza e del rapporto di verosimiglianza, facilitando il confronto con strumenti statistici più familiari. Si noti però che la scala appena proposto è discrezionale, quindi solamente una tra quelle possibili da utilizzare.

2.4.1 DEFAULT BAYES FACTOR

Nel contesto della replicazione, il *Bayes Factor* può essere utilizzato per confrontare due ipotesi specifiche riguardo l'effetto di interesse θ sulla base dei dati osservati nello studio di replicazione. L'approccio proposto da Rouder *et al.* (2009), si fonda sul confronto, attraverso i dati replicati, tra le seguenti ipotesi:

$$H_0: \theta = 0, \quad H_1: \theta \neq 0$$

L'obiettivo è quello di determinar se i dati della replica siano più plausibili sotto l'ipotesi che esista un effetto nella direzione dello studio originale che sotto l'ipotesi nulla.

Sotto H_0 , il parametro è fissato e la verosimiglianza marginale di H_0 si riduce alla verosimiglianza puntuale $f(y_r|\theta = 0)$. Poiché lo spazio parametrico sotto l'ipotesi nulla si riduce ad un singolo punto ($\Theta_0 = \{0\}$), il *Bayes Factor* assume la forma:

$$BF_{1:0}(y_r) = \frac{f(y_r|H_1)}{f(y_r|H_0)} = \frac{\int_{\Theta_1} f(y_r|\theta, H_1) f(\theta|H_1) d\theta}{f(y_r|\theta = 0)}$$

Sotto H_1 , è necessario però specificare una a priori $f(\theta|H_1)$, che rappresenti le credenze iniziali sull'effetto. Una delle scelte più utilizzate per questo tipo di test di ipotesi è stata

proposta da Jeffreys (1961), che assegnò a θ sotto H_1 una a priori di Cauchy centrata in 0 con parametro di scala $r = 1$:

$$H_1: \theta \sim \text{Cauchy}(0,1)$$

Una variabile aleatoria distribuita come una $\text{Cauchy}(\mu_0, r)$ è definita dalla seguente funzione di densità (Papoulis e Pillai, 2002):

$$f(\theta) = \frac{1}{\pi} \frac{r}{(\theta - \mu)^2 + r^2}, \quad \theta \in \mathbb{R}$$

Come illustrato nella Figura 1, la distribuzione di Cauchy presenta simmetria rispetto al proprio centro, analogamente alla distribuzione normale, ma con code considerevolmente più pesanti, tant'è che né la speranza matematica né la varianza esistono. Inoltre, si può provare che $\text{Cauchy}(0,1) \equiv t_1$, ovvero la distribuzione di Cauchy standard coincide con la distribuzione t di Student con un grado di libertà.

La scelta di questa a priori, nota come a priori di Jeffreys-Zellner-Shoemaker (JZS) (Zellner e Siow, 1980), è particolarmente conveniente. Infatti, una a priori JZS è “consistente rispetto all’informazione”: date due osservazioni misurate senza alcun rumore (i.e., $y_1 = y_2$), il *Bayes Factor* tende ad infinito, comportamento non garantito con altre a priori (Wagenmakers *et al.*, 2018). Inoltre, al limite della numerosità campionaria, il *Bayes Factor* così definito converge a infinito o a zero a seconda che sia vera l’ipotesi alternativa o quella nulla (*Bayes Factor Consistency*). Tuttavia, seppur desiderabile, questa convergenza presenta una limitazione: l’evidenza relativa contro H_0 crescerà indefinitamente all’aumentare della dimensione campionaria, a meno che l’ipotesi nulla non sia esattamente vera (Morey e Rouder, 2012).

La scelta del parametro di scala $r = 1$ non è esente da critiche. Infatti, la massa assegnata a valori estremi dell’effetto è spesso ritenuta eccessiva. Si può facilmente dimostrare che, per una $\text{Cauchy}(0,1)$, vi sia una probabilità del 50% che il valore assoluto del parametro superi 1:

$$P(|\theta| > 1 | H_1) = 2 \int_1^\infty \frac{1}{\pi} \frac{1}{\theta^2 + 1} d\theta = \frac{1}{\pi} \arctan(\theta) \Big|_1^\infty = \frac{1}{\pi} \left(\frac{\pi}{2} - \frac{\pi}{4} \right) = 0.5$$

È possibile ridurre il valore di scala al fine di alleggerire le code, ma valori eccessivamente piccoli di r implicherebbero una differenza troppo sottile tra H_0 e H_1 , rendendo più difficile ottenere un’evidenza convincente a favore di una delle due ipotesi.

Per bilanciare questa problematica, diversi studiosi (e.g., Morey e Rouder, 2012; Camerer *et al.*, 2018; Wagenmakers *et al.*, 2018) hanno optato per un parametro di scala pari a $\sqrt{2}/2 \approx 0.707$. Il confronto tra le distribuzioni proposte è rappresentato nella Figura 1, dove appare evidente quanto appena discusso.




Figura 1: Funzione di densità di $N(0,1)$, $\text{Cauchy}(0,1)$ e $\text{Cauchy}(0, \sqrt{2}/2)$

Nel contesto specifico della replicazione, la direzione della stima dell'effetto dell'originale $\hat{\theta}_o$ è nota. Pertanto, al fine di valutare la replicazione, ha senso concentrare la valutazione sull'ipotesi che nella replica l'effetto sia concorde. Infatti, utilizzare una a priori simmetrica rispetto a 0 implicherebbe assegnare ugual massa a priori anche a valori con segno opposto alla stima dell'effetto nello studio originale, introducendo così una componente d'incertezza inutile al fine di valutare il successo della replicazione.

Per questo motivo, come implementato da diversi studiosi già citati (e.g., Camerer *et al.*, 2018; Wagenmakers *et al.*, 2018), è possibile utilizzare una a priori di Cauchy *folded*, ossia ripiegata, nella direzione della stima dell'effetto originale, concentrando così tutta la massa della distribuzione sui valori di θ coerenti con $\text{sign}(\hat{\theta}_o)$. Come visibile nella Figura 2, il

ripiegamento elimina una delle due code della distribuzione, raddoppiando la densità nello spazio parametrico rimanente.




Figura 2: Funzione di densità di $\text{Cauchy}(0, \sqrt{2}/2)$, $\text{Cauchy}^+(0, \sqrt{2}/2)$ e $\text{Cauchy}^-(0, \sqrt{2}/2)$

Formalmente, una $\text{Cauchy}(\mu, r)$ *folded* è definita dalle seguenti funzioni di densità (Psarakis e Panaretos, 1990):

$$\theta \sim \text{Cauchy}^+(\mu, r) \leftrightarrow f^+(\theta) = \begin{cases} 2 \frac{1}{\pi} \frac{r}{(\theta - \mu)^2 + r^2}, & \theta \geq 0 \\ 0 & \theta < 0 \end{cases}$$

$$\theta \sim \text{Cauchy}^-(\mu, r) \leftrightarrow f^-(\theta) = \begin{cases} 0 & \theta > 0 \\ 2 \frac{1}{\pi} \frac{r}{(\theta - \mu)^2 + r^2}, & \theta \leq 0 \end{cases}$$

Si introduce quindi il *Bayes Factor Unilaterale* BF_{+0} (o BF_{-0}), che confronta l'ipotesi nulla H_0 con l'ipotesi alternativa direzionale rispetto alla stima dell'effetto nello studio originale. Supponendo $\text{sign}(\hat{\theta}_o) > 0$, si avrà:

$$H_+: \theta \sim \text{Cauchy}^+(0, \sqrt{2}/2), \quad BF_{+0} = \frac{\int_0^\infty f(y_r|\theta, H_+) f^+(\theta|H_+) d\theta}{f(y_r|\theta = 0)}$$

Analogamente, supposto $\text{sign}(\hat{\theta}_o) < 0$, si avrà $H_-: \theta \sim \text{Cauchy}^-(0, \sqrt{2}/2)$ e il corrispondente BF_{-0} . Calcolando quindi il BF_{+0} (o BF_{-0}) sui dati dello studio replicante, è possibile valutare se questi siano più plausibili sotto l'ipotesi di un effetto nella direzione dello studio originale oppure sotto l'ipotesi nulla.

La Figura 3 illustra l'andamento del BF_{10} al variare del parametro r , evidenziando come la scelta di r risulti coerente per i diversi valori di d . In particolare: per $d = 0.5$, il BF_{10} è leggermente inferiore a 1; per $d = 1$, è leggermente superiore a 1; per $d = 2$, è prossimo a 3.

La Figura 3 rappresenta come vari $BF_{1:0}$ al variare del parametro r , evidenziando come la scelta di $\sqrt{2}/2$ risulti coerente per i diversi valori di d . In particolare: per $d = 0.5$, il $BF_{1:0}$ è leggermente inferiore a 1; per $d = 1$, è leggermente superiore a 1; per $d = 2$, è prossimo a 3.




Figura 3: $BF_{1:0}$ come funzione di r per diversi valori di $d = \hat{\theta}_r/\hat{\theta}_o$, con $z_o = 1$. La linea verticale tratteggiata indica il valore convenzionale $r = \sqrt{2}/2$

Un valore $BF_{+0} > 1$ indica che i dati osservati nella replica sono più probabili sotto l'ipotesi di un effetto positivo che sotto l'ipotesi nulla, fornendo evidenza a favore del successo replicativo. Al contrario, $BF_{+0} < 1$ indica che i dati replicativi sono più coerenti con l'ipotesi nulla, segnalando un fallimento della replica.

Il criterio di *replication success* proposto da Camerer *et al.* (2018) è che il *Bayes Factor Unilaterale* appena introdotto, che viene denominato come *default Bayes Factor*, sia superiore 1. Questa soglia, tuttavia, è meno stringente rispetto all'interpretazione convenzionale di Kass e Raftery (1995), secondo cui un'evidenza è degna di menzione se il *Bayes Factor* è maggiore di 3. Per cui, nell'applicazione al dataset *RProjects* presentata di seguito, si terrà conto di entrambe le soglie al fine di fornire una valutazione articolata del successo di replicazione, distinguendo tra repliche che forniscono evidenza debole ma positiva ($1 < BF_{+0} < 3$) da quelle che forniscono evidenza moderata o forte ($BF_{+0} \geq 3$)

È opportuno precisare che il framework del *Bayes Factor Unilaterale* è stato originariamente sviluppato per il contesto del *t*-test. Nel dataset *RProjects*, tuttavia, gli effetti di interesse sono espressi come correlazioni. Pertanto, come nei precedenti casi, si è deciso di utilizzare la trasformazione di Fisher-*z*.

Calcolando quindi il BF_{+0} (o BF_{-0}) per l'intero dataset, si osserva che, dei 143 studi considerati, circa il 54% delle repliche (77 su 143) presenta un $BF_{+0} > 1$. Utilizzando la soglia $BF_{+0} > 1$ come criterio di *replication success*, la percentuale di successo risulta sostanzialmente in linea con il criterio di significatività statistica discusso nella sezione precedente, coerentemente con la loro interpretazione comune. Infatti, entrambi i criteri richiedono che la replica sia coerente con la direzione dell'originale e che vi sia evidenza contro l'ipotesi nulla.

Adottando invece una soglia più stringente $BF_{+0} > 3$, come raccomandato da Kass e Raftery (1995), la percentuale di successi si riduce al 45% (65 su 143). Per le ragioni discusse in precedenza, questa seconda soglia è da considerarsi più prudente e rigorosa nel valutare la replicabilità.

A differenza dei metodi frequentisti, il *Bayes Factor Unilaterale* appena introdotto quantifica l'evidenza empirica su una scala continua, permettendo di distinguere tra gradi diversi di evidenza per l'ipotesi alternativa. Tuttavia, è opportuno sottolineare come questo metodo non confronti direttamente le magnitudini degli effetti tra studio originale e replica.

Infatti, la *a priori* JZF rimane centrata in 0 indipendentemente dalla dimensione dell'effetto osservato nell'originale, e l'informazione proveniente da quest'ultimo si limita alla direzione dell'effetto, utilizzata per orientare il ripiegamento della *a priori*.

In altre parole, il metodo valuta se i dati della replica forniscono evidenza per la presenza di un effetto nella stessa direzione dello studio originale, ma non verifica se tale effetto sia

quantitativamente coerente con la stima originale, similmente a quanto visto con il *statistical significance criterion* (dal quale differisce principalmente per la natura continua della valutazione anziché dicotomica). Pertanto, i prossimi metodi introdotti terranno conto anche della grandezza della stima originale al fine di classificare il successo di replicazione.

2.4.2 REPLICATION BAYES FACTOR

Il *Replication Bayes Factor*, introdotto da Verhagen e Wagenmakers (2014), è un approccio *forward* bayesiano per la valutazione del successo replicativo. Questo metodo si distingue dal *default Bayes Factor* per l'utilizzo della grandezza della stima dell'effetto dello studio originale. Infatti, anziché confrontare l'ipotesi nulla con una a priori con moda in 0, viene confrontata con l'ipotesi secondo la quale l'effetto si distribuisca come la a posteriori dell'effetto dopo l'osservazione dello studio originale.

Formalmente, si confrontano le ipotesi:

$$H_0: \theta = 0, \quad H_1: \theta \sim f(\theta|y_o)$$

dove $f(\theta|y_o)$ è la stima a posteriori dello studio originale. Questa costruzione riflette un classico aggiornamento bayesiano: ciò che lo studio originale ha appreso sull'effetto, rappresentato dalla sua distribuzione a posteriori, diventa il punto di partenza per valutare la replica. In altre parole, si assume che lo studio originale abbia prodotto la migliore informazione disponibile sull'effetto, e si verifica se la replica conferma questa informazione.

Pawel e Held (2022) hanno indicato questa a priori come *advocacy prior*, sottolineando come questa a priori “difenda” la credibilità dello studio originale, in quanto rappresenta la distribuzione più vicina al risultato dello studio originale.

In questo caso è opportuno lavorare sulla scala di Fisher-z, assumendo così che l'effetto abbia distribuzione normale, coerentemente all'approccio adottato da Pawel e Held (2022). Date queste assunzioni, le ipotesi assumono la forma:

$$H_0: \theta = 0, \quad H_A: \theta \sim N(\hat{\theta}_o, \sigma_o^2)$$

L'ipotesi alternativa prevede quindi che la a priori sia una normale centrata nella stima dell'effetto nello studio originale con la rispettiva varianza. Il *Replication Bayes Factor* è quindi definito come:

$$BF_R \stackrel{\text{def}}{=} BF_{0:A}(y_r) = \frac{f(y_r|\theta = 0)}{\int_{\mathbb{R}} f(y_r|\theta, H_A)f(\theta|H_A)d\theta}$$

È possibile definire esplicitamente il BF_R come (Pawel e Held, 2022):

$$BF_R = \sqrt{1+c} \exp \left\{ -\frac{z_o^2}{2} \left(d^2 c - \frac{(1-d)^2}{1/c + 1} \right) \right\}$$

dove $d = \hat{\theta}_r/\hat{\theta}_o$ è il rapporto tra le stime dell'effetto e $c = \sigma_o^2/\sigma_r^2$ è il rapporto tra le varianze. Un valore di $BF_R < 1$ indica che i dati della replica sono più plausibili sotto l'ipotesi che l'effetto sia distribuito come la stima dello studio originale che sotto l'ipotesi di nullità dell'effetto. Pertanto, piccoli valori di BF_R suggeriscono il successo nella replicazione. La Figura 4 evidenzia il legame tra il BF_R e c .




Figura 4: BF_R come funzione di $c = \sigma_o^2/\sigma_r^2$ per diversi valori di $d = \hat{\theta}_r/\hat{\theta}_o$, con $z_o = 2$. La linea orizzontale tratteggiata indica la soglia convenzionale $BF_R = 1/3$

A differenza del *default Bayes Factor*, il *Replication Bayes Factor* incorpora esplicitamente la dimensione dell'effetto osservato nello studio originale, non solo la sua direzione. Questa differenza ha implicazioni profonde per la sensibilità del metodo all'inflazione dell'effetto originale. Infatti, qualora l'effetto originale sia sovrastimato, per i vari fenomeni discussi

nel Capitolo 1, l'*advocacy prior* sarà eccessivamente ottimista, in quanto centrata su un valore inflazionato. In questo scenario, anche una replica ben condotta con un effetto reale ma più piccolo dell'originale produrrà un BF_R superiore a quanto atteso, conducendo eventualmente ad un insuccesso della replicazione. Questo comportamento è simile a quello del *prediction interval criterion* discusso nel capitolo precedente.

Applicando questo criterio al dataset *RProjects* si osserva che, dei 143 studi considerati, circa il 55% delle replicazioni (79 su 143) presenta un $BF_R < 1$, indicando evidenza, seppur talvolta debole, a favore della compatibilità tra replica e studio originale. Il restante 45% (64 su 143) presenta invece un Bayes Factor superiore a 1, suggerendo che i dati replicativi sono più coerenti con l'ipotesi nulla che con l'*advocacy prior* basata sull'effetto originale. Adottando una soglia più stringente $BF_R < 1/3$, la percentuale di successi si attesta intorno 50% (71 su 143).

La percentuale di successo con soglia base risulta sostanzialmente identica a quella ottenuta con il *default Bayes Factor* (55% vs 54%), mentre con soglia stringente emerge una differenza leggermente più marcata (50% vs 45%). Questa convergenza è notevole considerato che i due metodi si fondano su prior radicalmente differenti.

Un'analisi dei casi discordanti nella classificazione del successo con soglia più stringente (8 osservazioni, pari al 5.6% del dataset) rivela due pattern distinti:

- Nel caso di una forte riduzione nella magnitudine della stima degli effetti dall'originale alla replica, il *default Bayes Factor* fornisce evidenza forte mentre il *Replication Bayes Factor* fornisce solo evidenza debole: l'effetto replicato risulta abbastanza grande da essere convincentemente diverso da zero ma troppo distante dall'originale per essere compatibile con quest'ultimo;
- Nel caso di effetti replicati moderati (0.12 - 0.32) e sufficientemente vicini agli originali, il *Replication Bayes Factor* fornisce evidenza forte mentre il *default Bayes Factor* fornisce solo evidenza debole, in quanto le stime delle repliche non si discostano sufficientemente da 0.

Questa analisi evidenzia come i due metodi rispondano a domande complementari: il *default Bayes Factor* fornisce evidenza sulla presenza di un effetto nella replica diverso da zero e in direzione della stima originale, mentre il *Replication Bayes Factor* fornisce evidenza sulla compatibilità della replica con l'originale anche in termini di grandezza dell'effetto.

Entrambi i metodi operano in modalità *forward Bayes*, specificando la *a priori* per derivare inferenze *a posteriori*. Nella sezione successiva si esaminerà un approccio radicalmente diverso, lo *Sceptical Bayes Factor* di Pawel e Held (2022), che inverte questa logica, adottando il menzionato approccio *Reverse Bayes* formulato da Good (Good, 1950), determinando quale livello di scetticismo iniziale i dati replicativi riescono a superare.

2.4.3 SCEPTICAL BAYES FACTOR

Mentre il *default Bayes Factor* e il *Replication Bayes Factor* operano in un framework *Forward Bayes*, lo *Lo Sceptical Bayes Factor*, introdotto da Pawel e Held (2022), adotta un approccio di *Reverse Bayes*, invertendo la logica inferenziale: anziché partire da un *a priori* per valutare i dati, si determina quale livello di scetticismo iniziale i dati replicativi riescono a superare.

L'idea fondamentale del metodo è che, se un risultato scientifico è effettivamente credibile, questo dovrebbe essere in grado di convincere anche una persona razionalmente scettica, la quale inizialmente assegna bassa probabilità alla possibilità che l'effetto esista.

La procedura si articola in due fasi:

1. Fase dei dati originali: si determina una prior che rispecchi una posizione scettica sull'esistenza dell'effetto (*sceptical prior*), in modo che lo studio originale produca un'evidenza pari a γ a favore della suddetta prior rispetto all'ipotesi di nullità dell'effetto;
2. Fase dei dati replicati: si misura l'eventuale successo nella replicazione confrontando quanto i dati replicati siano compatibili con una *advocacy prior* rispetto alla *sceptical prior*. Se l'evidenza prodotta dalla replica è almeno pari a quella prodotta dall'originale γ , la replicazione è considerata di successo.

In altre parole, affinché vi sia un successo replicativo, la replica deve essere almeno altrettanto convincente dell'originale: se l'originale ha convinto uno scettico ad un certo livello γ , la replica deve convincere almeno lo stesso livello di scetticismo, o preferibilmente uno ancora più elevato.

Formalmente, si assume la seguente struttura per i due studi (originale e replica):

$$\hat{\theta}_o | \theta \sim N(\theta, \sigma_o^2), \quad \hat{\theta}_r | \theta \sim N(\theta, \sigma_r^2)$$

A questo punto, osservato lo studio originale con stima $\hat{\theta}_o$ e relativa varianza σ_o^2 , si procede, fissato un livello di scetticismo $\gamma \in (0,1)$, a confrontare le seguenti ipotesi sulla a priori dell'effetto attraverso un Bayes Factor $BF_{0:S}(\hat{\theta}_o; g_\gamma)$ calcolato sui dati originali:

$$H_0: \theta = 0, \quad H_S: \theta \sim N(0, g_\gamma \cdot \sigma_o^2)$$

dove $g_\gamma \geq 0$ è fissato in modo riesca:

$$BF_{0:S}(\hat{\theta}_o; g_\gamma) = \frac{f(y_o | \theta = 0)}{\int_{\Theta} f(y_o | \theta, H_S) f(\theta | H_S) d\theta} = \gamma$$

Il parametro g_γ , definito come *Sufficiently Sceptical Relative Prior Variance*, determina il livello di scetticismo: valori grandi di g_γ corrispondono ad una a priori diffusa che assegna probabilità significativa anche a valori molto distanti da zero, rappresentando uno scettico poco esigente; valori piccoli di g_γ corrispondono a un prior concentrato vicino a zero, rappresentando uno scettico molto esigente, convinto che l'effetto sia nullo o trascurabile.

La forma esplicita di $BF_{0:S}$ è:

$$BF_{0:S}(\hat{\theta}_o; g_\gamma) = \sqrt{1 + g_\gamma} \cdot \exp \left\{ -\frac{1}{2} \cdot \frac{g_\gamma}{1 + g_\gamma} \cdot z_o^2 \right\},$$

dove $z_o = \hat{\theta}_o / \sigma_o$. Imponendo $BF_{0:S}(\hat{\theta}_o; g_\gamma) = \gamma$ e risolvendo per g_γ , si ottiene il valore della *sceptical prior* corrispondente al livello di scetticismo fissato γ . L'esistenza della soluzione tuttavia non è però garantita, in quanto dipende dal valore di z_o . Dalla Figura 5 si può osservare come, più è convincente e affidabile il risultato dello studio originale, ossia quanto più è grande $|z_o|$, minore è il g_γ richiesto affinché il $BF_{0:S}(\hat{\theta}_o; g_\gamma)$ sia pari ad una soglia prefissata γ .

Pawel e Held hanno inoltre dimostrato come, per $|z_o| \rightarrow \infty$, fissato γ , g_γ converga a zero. D'altro canto, qualora $|z_o|$ non sia sufficientemente elevato, il $BF_{0:S}(\hat{\theta}_o; g_\gamma)$ tenderà a crescere in funzione di g_γ e non sarà mai pari alla soglia di scetticismo γ . In tal caso, g_γ non è definito.




Figura 5: $BF_{0:S}(\hat{\theta}_o; g_\gamma)$ come funzione di g_γ per diversi valori di $z_o = \hat{\theta}_o/\sigma_o$. La linea orizzontale tratteggiata indica la soglia convenzionale $BF = 1/3$

Osservato lo studio di replica con stima $\hat{\theta}_r$ e relativa varianza σ_r^2 , si procede a confrontare le seguenti ipotesi attraverso un Bayes Factor $BF_{S:A}(\hat{\theta}_r; g_\gamma)$ calcolato sui dati della replica:

$$H_S: \theta \sim N(0, g_\gamma \cdot \sigma_o^2), \quad H_A: \theta \sim N(\hat{\theta}_o, \sigma_o^2)$$

dove H_A è l'ipotesi basata sull'*advocacy prior*, utilizzata anche nel *Replication Bayes Factor*. La forma esplicita di $BF_{S:A}$ è:

$$BF_{S:A}(\hat{\theta}_r; g_\gamma) = \sqrt{\frac{1/c + 1}{1/c + g_\gamma}} \cdot \exp \left\{ -\frac{z_o^2}{2} \cdot \left[\frac{d^2}{1/c + g_\gamma} - \frac{(d-1)^2}{1/c + 1} \right] \right\},$$

dove $d = \hat{\theta}_r/\hat{\theta}_o$ è il rapporto tra stima le stime degli effetti e $c = \sigma_o^2/\sigma_r^2$ è il rapporto tra le varianze delle stime.

Come condizione di successo di replicazione è naturale considerare l'evento in cui l'evidenza prodotta dallo studio di replicazione a favore dell'*advocacy prior* rispetto alla *sceptical prior* è maggiore o almeno uguale all'evidenza con cui lo studio originale supporta la *sceptical prior* rispetto all'ipotesi nulla.




Figura 6: $BF_{S:A}(\hat{\theta}_r; g_\gamma)$ come funzione di g_γ per diversi valori di $z_o = \hat{\theta}_o/\sigma_o$. La linea orizzontale tratteggiata indica la soglia convenzionale $BF = 1/3$

Nella Figura 6 è possibile notare come le tre curve, rappresentanti il $BF_{S:A}$ per diversi valori di $|z_o|$, pur partendo da livelli diversi, tendono a convergere verso valori simili (e decrescenti) per g_γ elevato, riflettendo il fatto che, al diminuire dello scetticismo, l'evidenza a favore dell' *advocacy prior* rispetto aumenta progressivamente, indipendentemente dalla forza dell'evidenza originale.

Formalmente, la condizione per il successo di replicazione è dunque data da:

$$BF_{S:A}(\hat{\theta}_r; g_\gamma) \leq BF_{0:S}(\hat{\theta}_o; g_\gamma) = \gamma$$

In questo caso parleremo di successo di replicazione al livello γ . Tuttavia, questa procedura dipende intrinsecamente dalla scelta arbitraria di γ . Pertanto, Pawel e Held hanno proposto di calcolare il minimo γ per cui è raggiunto il successo di replicazione. Questa quantità, definita come *Sceptical Bayes Factor*, è pari a:

$$BF_S \stackrel{\text{def}}{=} \inf\{\gamma \mid BF_{S:A}(\hat{\theta}_r; g_\gamma) \leq \gamma\}$$

A livello interpretativo lo *Sceptical Bayes Factor* è una misura quantitativa del successo di replicazione. Un valore di $BF_S < 1$ indica che i dati della replica sono più plausibili sotto l'ipotesi "avvocata" che sotto l'ipotesi "scettica". Pertanto, più piccolo è BF_S maggiore è il grado di successo nella replicazione, fissato un certo valore scetticismo.




Figura 7: $BF_{S:A}(\hat{\theta}_r; g_\gamma)$ e $BF_{0:S}(\hat{\theta}_o; g_\gamma)$ come funzioni di g_γ per diversi valori di $z_o = \hat{\theta}_o/\sigma_o$ e $d = \hat{\theta}_r/\hat{\theta}_o$, con $c = 1$. Le croci indicano il BF_S , qualora questo sia definito.

Come visibile nella Figura 7, possiamo distinguere tre diversi casi:

- $BF_{S:A}(\hat{\theta}_r; g_\gamma) > BF_{0:S}(\hat{\theta}_o; g_\gamma)$ per ogni g_γ : in questo scenario la replica non riesce mai a fornire evidenza sufficiente rispetto all'originale, indipendentemente dal livello di scetticismo considerato. Pertanto, il successo di replicazione non è raggiungibile a nessun livello γ e BF_S è indefinito;
- $BF_{S:A}(\hat{\theta}_r; g_\gamma) < BF_{0:S}(\hat{\theta}_o; g_\gamma)$ per ogni g_γ : in questo caso la replica fornisce sempre evidenza superiore a quella dell'originale, indipendentemente dal livello di scetticismo. Pertanto, BF_S risulta il minimo raggiungibile da $BF_{0:S}(\hat{\theta}_o; g_\gamma)$;

- c) $BF_{S:A}(\hat{\theta}_r; g_\gamma) \leq BF_{0:S}(\hat{\theta}_o; g_\gamma)$ per qualche g_γ : essendo le due misure continue, il BF_S risulta essere l'ordinata del punto di intersezione tra $BF_{S:A}(\hat{\theta}_r; g_\gamma)$ e $BF_{0:S}(\hat{\theta}_o; g_\gamma)$.

A differenza dei metodi bayesiani precedenti, il BF_S , rappresentato dalle croci nella Figura 7, non richiede di specificare arbitrariamente una a priori, bensì questa viene ricavata in base al livello di scetticismo, il quale emerge come minimo livello superabile dalla replica e non necessita quindi di essere scelto arbitrariamente a sua volta.

Consonni e Egidi (2025) hanno proposto un'estensione allo *Sceptical Bayes Factor*, che utilizza una mistura tra una a priori puntuale centrata in zero e una a priori scettica come *sceptical prior*. Formalmente, l'ipotesi H_S è sostituita da:

$$H_{SM}: \theta \sim \psi_\gamma \delta_0 + (1 - \psi_\gamma) N(\theta, h_\gamma \cdot \sigma_o^2)$$

dove: $0 \leq \psi_\gamma \leq 1$ è il peso della combinazione e δ_0 è la misura di Dirac per $\theta = 0$. La a priori appena introdotta è denominata *sceptical mixture prior*. La coppia (ψ_γ, h_γ) è definita in modo che riesca:

$$BF_{0:SM}(\hat{\theta}_o; \psi_\gamma, h_\gamma) = \frac{f(y_o | \theta = 0)}{\int_{\Theta} f(y_o | \theta, H_{SM}) f(\theta | H_{SM}) d\theta} = \gamma$$

Si può provare che:

$$BF_{0:SM}(\hat{\theta}_o; \psi_\gamma, h_\gamma) = \frac{1}{\psi_\gamma + (1 - \psi_\gamma) BF_{S:0}(\hat{\theta}_o; h_\gamma)}$$

dove $BF_{S:0}(\hat{\theta}_o; h_\gamma)$ è il reciproco di $BF_{0:S}(\hat{\theta}_o; h_\gamma)$ definito in precedenza, con $g_\gamma = h_\gamma$. Pertanto, la *sceptical prior* risulta essere un caso particolare (i.e., $\psi_\gamma = 0, h_\gamma = g_\gamma$) della *sceptical mixture prior*. Inoltre, è dimostrabile che:

$$BF_{SM:A}(\hat{\theta}_r; \psi_\gamma, h_\gamma) = \psi_\gamma BF_R + (1 - \psi_\gamma) BF_{S:A}(\hat{\theta}_r; h_\gamma)$$

dove BF_R è il *Replication Bayes Factor* e $BF_{S:A}(\hat{\theta}_r; h_\gamma)$ il *Bayes Factor* definito in precedenza, con $g_\gamma = h_\gamma$. Infine, è possibile definire lo *Sceptical Mixture Bayes Factor* come:

$$BF_{SM} \stackrel{\text{def}}{=} \inf\{\gamma | BF_{SM:A}(\hat{\theta}_r; \psi_\gamma, h_\gamma) \leq \gamma\}$$

Questo metodo risulta essere più robusto e maggiormente capace di gestire i conflitti tra a priori e dati. Infatti, ψ_γ è determinato imponendo che il conflitto prior-data sia pari ad un certo α , convenzionalmente pari a 0.10, 0.05 o 0.01, dove più piccolo è α , maggiore è il conflitto. Così facendo, il BF_{SM} tende ad essere più conservativo del BF_S , come visibile nella Figura 8.




Figura 8: $BF_{S:A}(\hat{\theta}_r; g_\gamma)$, $BF_{0:S}(\hat{\theta}_0; g_\gamma)$, $BF_{0:SM}(\hat{\theta}_0; \psi_\gamma, h_\gamma)$ $BF_{SM:A}(\hat{\theta}_r; \psi_\gamma, h_\gamma)$ come funzioni della varianza relativa g_γ o h_γ , con $\alpha = 0.1$, $z_o = 3$, $z_r = 2.5$ e $c = 1$. La croce nera indica il BF_S , mentre quella blu il BF_{SM} .

Un ulteriore concetto strettamente correlato allo Sceptical Bayes Factor è lo *sceptical p-value*, introdotto da Held (2020). Mentre il BF_S opera interamente nel framework bayesiano, lo *sceptical p-value* fornisce un ponte tra l'inferenza bayesiana e quella frequentista, offrendo una misura complementare del successo replicativo, interpretabile anche da chi non è solito all'approccio bayesiano.

La procedura è analoga a quella del BF_S , ma vengono utilizzati gli intervalli di credibilità anziché i *Bayes Factor*. Inizialmente si considera una *sceptical prior* $\theta \sim N(0, \tau_\alpha^2)$, dove τ_α^2 è posto in modo tale che l'intervallo di credibilità al livello $(1 - \alpha)$ per θ , basato sulla a

posteriori $\theta|\hat{\theta}_o, \tau_\alpha^2$, non includa 0. Qualora la probabilità alla coda della distribuzione a priori predittiva $\hat{\theta}_r|\tau_\alpha^2 \sim N(0, \tau_\alpha^2 + \sigma_r^2)$ sia minore di α , avremo il successo di replicazione.

Il minimo livello α per cui vi è successo di replicazione è proprio lo *sceptical p-value*, indicato con p_S . A differenza del BF_S , p_S è sempre calcolabile ed è pari a (Pawel e Held, 2022):

$$p_S = 1 - \Phi(z_S)$$

dove:

$$z_S^2 = \begin{cases} z_H^2/2 & \text{se } c = 1 \\ \frac{1}{c-1} \left\{ \sqrt{z_A^2 [z_A^2 + (c-1)z_H^2]} - z_A^2 \right\} & \text{se } c \neq 1 \end{cases}$$

con $z_H^2 \stackrel{\text{def}}{=} 2/(1/z_o^2 + 1/z_r^2)$ la media armonica del quadrato degli z-values dei due studi e $z_A^2 \stackrel{\text{def}}{=} (z_o^2 + z_r^2)/2$ la media aritmetica del quadrato degli z-values dei due studi. Questo criterio richiede l'evidenza da entrambi gli studi, coerentemente con alcuni dei metodi frequentisti, ed evita lo *shrinkage paradox*. È stata proposta un'ulteriore versione ricalibrata del p_S , dove z_S viene corretto attraverso la sezione aurea $\varphi \stackrel{\text{def}}{=} (1 + \sqrt{5})/2$ (Held, Micheloud e Pawel, 2022):

$$\tilde{p}_S \stackrel{\text{def}}{=} 1 - \Phi(z_S \sqrt{\varphi})$$

Questa versione risulta essere più permissiva, in termini di successo di replicazione, rispetto allo *Sceptical Bayes Factor* e alla versione non ricalibrata p_S .

Applicando il BF_S al dataset *RProjects* si osserva che, dei 143 studi considerati, circa il 23% delle replicazioni (33 su 143) il metodo non produce un risultato definito: 8 studi rientrano nel caso a), in cui non esiste un valore di g_γ tale per cui la replica risulta di successo; per i restanti 25 non è stato possibile trovare un'intersezione. La frazione sostanziale di casi indefiniti è un aspetto distintivo dello *Sceptical Bayes Factor* rispetto agli altri metodi bayesiani, che producono invece sempre un risultato. Dei rimanenti 110 studi con BF_S definito, 7 appartengono al caso b), in cui la replica fornisce sempre evidenza superiore a quella dell'originale, e 103 al caso c) con un'intersezione calcolabile. Tra questi 110, il 90% (99 su 110) presenta un $BF_S < 1$, mentre la percentuale di successi si riduce al 49% (54 su 110) abbassando la soglia a $1/3$. Pertanto, considerando anche i 7 studi del caso b) ed escludendo dal computo i 25 studi nei quali non è stato possibile definire un risultato, il 52% (61 su 118) degli studi replicati è di successo.

Lo *sceptical p-value*, a differenza dello *Sceptical Bayes Factor*, è sempre calcolabile e produce dei risultati non dissimili: il 52% (74 su 143) degli studi replicati presenta un p_S inferiore alla soglia 0.005. Utilizzando una soglia più permissiva (0.05), la percentuale di successi di replicazione sale all'89% (127 su 143).

Infine, il *recalibrated sceptical p-value*, come prevedibile, ottiene una percentuale di successi maggiore della versione non ricalibrata, pari al 71% (102 su 143) con una soglia di 0.005 e al 99% (141 su 143) con una soglia di 0.05.

2.5 ANALISI DEI RISULTATI DEL DATASET

Per rendere più agevole il confronto dei tassi di successo replicativo ottenuti nell'applicazione al dataset *RProjects*, si riportano qui di seguito nella Tabella 2 e nella Tabella 3. Le tabelle tengono conto del numero di studi valutati per ciascun metodo, suddivisi tra approccio frequentista e approccio bayesiano.

Si tenga presente che i risultati dipendono radicalmente dalle soglie di significatività scelte, oltre che dalle caratteristiche intrinseche di ciascun metodo.

Metodi Frequentisti			
Metodo	Successi	Totale Studi	Percentuale
Statistical Significance Criterion	67	132	51%
Statistical Significance Criterion – Meta Analysis	81	132	61%
Prediction Interval Criterion	55	143	38%
Small Telescope Approach	37	143	26%

Tabella 2: risultati metodi frequentisti

Lo *Statistical Significance Criterion* meta-analitico mostra il più alto tasso di successo tra i metodi frequentisti. Come già detto, questo metodo è il più soggetto all'inflazione dell'effetto nello studio originale e pertanto è coerente che risulti il più ottimistico tra quelli proposti. Invece, lo *Small Telescope Approach* presenta il tasso di successo più basso tra i metodi frequentisti, coerentemente con la sua impostazione più selettiva basata sulla potenza statistica dello studio originale.

Come già visto in precedenza, i metodi frequentisti offrono un'interpretazione binaria del risultato della replicazione (successo/fallimento), rendendo l'analisi percentuale immediata e facilmente comparabile tra metodi, ma comunque fortemente dipendente dalla soglia di significatività adottata.

Metodi Bayesiani			
Metodo	Successi	Totale Studi	Percentuale
Default Bayes Factor	65	143	45%
Replication Bayes Factor	71	143	50%
Sceptical Bayes Factor	61	118	52%
Sceptical p -value	74	143	52%
Recalibrated Sceptical p -value	102	143	71%

Tabella 3: risultati metodi Bayesiani

Il *Recalibrated Sceptical p -value* risulta essere il più ottimista in termini di successo di replicazione tra i metodi bayesiani, confermando quanto discusso nel precedente capitolo. Si tenga però a mente che lo *Sceptical p -value* si colloca a cavallo tra i due framework (frequentista e bayesiano), rappresentando un approccio intermedio. Il *Default Bayes Factor*, sorprendentemente, è il più selettivo in questo dataset.

Nei metodi bayesiani, pur essendo possibile una valutazione dicotomica, la scala continua dell'evidenza permette interpretazioni più sfumate e probabilmente robuste. Pertanto, sebbene richiedano conoscenze statistiche più approfondite, i metodi bayesiani forniscono un framework più flessibile e adattabile, risultando particolarmente adatti all'analisi della replicabilità.

CAPITOLO 3: REVERSE BAYES SHRINKAGE

Come discusso nel capitolo precedente, la letteratura offre molteplici strumenti per la valutazione del successo replicativo, ciascuno fondato su presupposti metodologici differenti. Tra questi, i metodi bayesiani si distinguono dai metodi frequentisti per la possibilità di quantificare la concordanza tra studio originale e replica su una scala continua.

Di particolare interesse per lo sviluppo della presente tesi è l'approccio noto come *Reverse Bayes*, già introdotto nel Capitolo 2 con riferimento allo *Sceptical Bayes Factor* di Pawel e Held (2022). A differenza del framework *Forward Bayes*, in cui si specifica un'opportuna distribuzione a priori sul parametro d'interesse e si aggiorna tale distribuzione alla luce dei dati osservati, ottenendo una distribuzione a posteriori, l'approccio *Reverse Bayes* inverte la direzione del ragionamento inferenziale, partendo da una distribuzione a posteriori desiderata, per risalire, attraverso il teorema di Bayes, alla distribuzione a priori che l'avrebbe generata.

L'intuizione alla base del metodo che verrà sviluppato nel presente capitolo consiste nell'applicare questa stessa logica per ricalibrare la stima dello studio originale. L'obiettivo è determinare la grandezza dell'effetto e il grado di precisione che lo studio originale avrebbe dovuto possedere affinché la sua stima risulti pienamente concorde con quella fornita dallo studio replicativo. Si tratta quindi di una calibrazione a posteriori per valutare quanto i due studi possano ritenersi opportunamente simili. Si noti come questo prende ampiamente spunto dalla letteratura già analizzata, in particolare con il concetto di a priori scettica (Pawel e Held, 2022). Il presente capitolo sviluppa dunque un metodo che, attraverso intuitive tecniche di inferenza bayesiana, permette di rispondere a questo interrogativo dapprima in forma chiusa, quindi mediante un approccio *Empirical Bayes* e, infine, attraverso trattazione *Full Bayes*, fornendo così un nuovo strumento diagnostico per la valutazione della replicabilità, oltre che uno strumento teorico di riferimento per il successivo capitolo.

3.1 INTRODUZIONE AL NUOVO APPROCCIO

Come anticipato, l'idea alla base del metodo proposto consiste nel rivalutare o, più precisamente, nel ricalibrare lo studio originale affinché la sua stima, in termini sia di grandezza dell'effetto che di precisione, risulti compatibile con quella osservata nello studio

replicativo. A tal fine, si è scelto di costruire tale ricalibrazione attraverso un semplice ed intuitivo meccanismo di inferenza bayesiana.

Si assegni al parametro d'interesse θ una distribuzione a priori centrata in 0, con varianza proporzionale a quella dello studio originale:

$$\theta \sim N(0, \alpha \cdot \sigma_o^2)$$

dove $\alpha > 0$ è un parametro di scala che regola quanto tale prior sia diffusa. In altri termini, valori piccoli di α concentrano la massa di probabilità attorno allo zero, rappresentando una posizione fortemente scettica circa l'esistenza dell'effetto, mentre valori grandi di α producono una prior via via più diffusa, tendenzialmente non informativa. Quindi, si tratta la stima ottenuta dallo studio originale $\hat{\theta}_o$ come l'informazione empirica ottenuta da un esperimento, trattandola come una sorta di verosimiglianza:

$$\hat{\theta}_o | \theta \sim N(\theta, \sigma_o^2)$$

Combinando le due distribuzioni attraverso il teorema di Bayes, essendo entrambe distribuzioni gaussiane per ipotesi, si ottiene una distribuzione a posteriori anch'essa gaussiana, i cui parametri sono ricavabili attraverso le usuali formule di combinazione coniugata normale-normale. La precisione a posteriori è pari alla somma delle precisioni della prior e della verosimiglianza:

$$\frac{1}{\alpha \sigma_o^2} + \frac{1}{\sigma_o^2} = \frac{\alpha + 1}{\alpha} \frac{1}{\sigma_o^2}$$

da cui, invertendo, otteniamo la varianza a posteriori:

$$\frac{\alpha}{\alpha + 1} \sigma_o^2$$

La media a posteriori, a sua volta, è una media pesata tra la media della prior, pari a 0, e la stima osservata $\hat{\theta}_o$, con pesi proporzionali alle rispettive precisioni:

$$\left(0 \frac{1}{\alpha \sigma_o^2} + \hat{\theta}_o \frac{1}{\sigma_o^2}\right) \frac{\alpha}{\alpha + 1} \sigma_o^2 = \frac{\alpha}{\alpha + 1} \hat{\theta}_o$$

La distribuzione a posteriori così ottenuta, che d'ora in avanti denoteremo tramite l'ipotesi H_α , risulta pertanto:

$$H_\alpha: \theta \sim N\left(\frac{\alpha}{\alpha + 1} \hat{\theta}_o, \frac{\alpha}{\alpha + 1} \sigma_o^2\right)$$

Sebbene la formulazione sia già interpretabile essa presenta un limite pratico non trascurabile: il parametro α varia sull'intero semiasse positivo $(0, \infty)$, il che ne rende meno agevole sia l'interpretazione intuitiva sia la successiva esplorazione numerica. Si è pertanto scelto di introdurre la seguente riparametrizzazione:

$$\delta \stackrel{\text{def}}{=} \frac{\alpha}{\alpha + 1}$$

da cui $\alpha = \frac{\delta}{1-\delta}$. Essendo $\alpha \in (0, \infty)$, si ha che $\delta \in (0,1)$. La relazione tra le due variabili è rappresentata nella Figura 9.




Figura 9: Confronto grafico tra i parametri α e δ

Applicando la riparametrizzazione, l'ipotesi, che denoteremo con H_δ , assume la forma più compatta:

$$H_\delta: \theta \sim N(\delta \hat{\theta}_o, \delta \sigma_o^2)$$

Si osservi come questa distribuzione a posteriori rappresenti, di fatto, una versione ristretta della stima originale: sia la media che la varianza risultano moltiplicate per il medesimo fattore di restringimento $\delta \in (0,1)$. Per $\delta \rightarrow 1$, l'ipotesi H_δ coincide con H_A , introdotta in precedenza, mentre per $\delta \rightarrow 0$, l'ipotesi coincide con H_0 .

L'idea è quindi quella di confrontare l'ipotesi appena introdotta con l'ipotesi che rappresenta l'evidenza fornita dallo studio replicativo

$$H_R: \theta \sim N(\hat{\theta}_r, \sigma_r^2),$$

al fine di stimare il parametro di restringimento δ applicato allo studio originale affinché vi sia concordanza tra le due ipotesi. Dalla Figura 10 si può osservare come la distribuzione descritta dall'ipotesi H_R differisca al variare del parametro δ .




Figura 10: Variazione dell'ipotesi distributiva H_δ per diversi valori di δ , con $\hat{\theta}_o = 2$ e $\sigma_o^2 = 1$

Questo approccio risulta particolarmente coerente con il fenomeno dell'inflazione della stima dell'effetto, ampiamente discussa nel Capitolo 1 (Simonsohn *et al.* 2014). Lo studio replicativo tende infatti a produrre stime dell'effetto più contenute e, in virtù della maggiore numerosità campionaria tipicamente impiegata nelle repliche, più precise rispetto allo studio originale. In tale contesto, il più ricorrente nella pratica, il parametro δ quantifica precisamente quanto occorra restringere l'effetto originale, comprimendone contestualmente sia l'entità sia la varianza, affinché la distribuzione risultante risulti concorde con quanto osservato nello studio di replica. In altre parole, il parametro δ rappresenta una sorta di validazione a posteriori del successo di replicazione.

L'idea metodologica può dunque essere riassunta come segue: anziché domandarsi se la replica confermi o smentisca l'originale, ci si chiede quale grado di restringimento renda i due studi, in termini di effetto e precisione, coerenti tra loro. Un valore di δ prossimo ad 1 indicherà che è stato necessario un restringimento modesto per raggiungere la concordanza, segno di un effetto originale sostanzialmente confermato dalla replica. D'altra parte, un valore di δ prossimo a 0 indicherà che solo un restringimento quasi totale dell'effetto originale consente di renderlo compatibile con l'evidenza replicativa, segnalando così una sostanziale incompatibilità tra i due studi. Pertanto, il metodo è stato soprannominato come *Reverse Bayes Shrinkage (RBS)*.

Le sezioni seguenti del presente capitolo sono dedicate alla calibrazione del parametro δ , interpretandolo dapprima come parametro fissato e quindi come variabile aleatoria, e l'applicazione di questo nuovo approccio sul dataset *RProjects*.

3.2 CALIBRAZIONE DEL PARAMETRO δ

Come accennato pocanzi, è necessario individuare un criterio per calibrare il parametro δ , elemento chiave del metodo appena introdotto. Si tratta, in sostanza, di stimare il parametro δ tale per cui sia minima la divergenza tra le due distribuzioni descritte dalle ipotesi H_δ e H_R . Per far ciò, è possibile ricorrere a diversi metodi, presentati qui di seguito.

3.2.1 DIVERGENZA DI KULLBACK-LIEBER

Una delle misure più utilizzate per confrontare due distribuzioni di probabilità è la *divergenza di Kullback-Lieber* (Kullback e Leibler, 1951), così definita per due distribuzioni continue f_1, f_2 con stesso supporto:

$$KL[f_1||f_2] \stackrel{\text{def}}{=} \int f_1(y) \log \frac{f_1(y)}{f_2(y)} dy. \quad (3.1)$$

Questa misura, per costruzione non-simmetrica, quantifica l'informazione mediamente persa nell'approssimare f_1 con f_2 .

Per due distribuzioni normali univariate $f_1(y) = N(y|\mu_1, \sigma_1^2)$ e $f_2(y) = N(y|\mu_2, \sigma_2^2)$ è possibile dimostrare, risolvendo esplicitamente l'integrale, che la divergenza (3.1) assume la seguente forma chiusa:

$$KL[f_1||f_2] = \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}. \quad (3.2)$$

Questo risultato si presta perfettamente al confronto tra H_δ e H_R , entrambe gaussiane per costruzione. Resta tuttavia da risolvere una questione, conseguenza diretta dell'asimmetria della misura, ossia la scelta su quale delle due distribuzioni debba fungere da distribuzione target f_1 e quale da distribuzione approssimante f_2 . Infatti, la scelta della direzione della divergenza non è indifferente, ed è un tema ben noto nella letteratura sull'inferenza variazionale (e.g., Bishop, 2006). Nel contesto del presente lavoro, lo studio replicativo H_R rappresenta l'evidenza empirica più recente e maggiormente affidabile, l'obiettivo verso cui ricalibrare lo studio originale, e costituisce pertanto la più naturale scelta come distribuzione target. Pertanto, la distribuzione caratterizzante H_R sarà trattata come la distribuzione target f_1 , mentre quella caratterizzante H_δ come l'approssimante f_2 .

Si perviene così alla seguente quantità, che utilizzeremo per calibrare δ :

$$KL_\delta(\hat{\theta}_o, \hat{\theta}_r; \delta) \stackrel{\text{def}}{=} KL[N(\hat{\theta}_r, \sigma_r^2) || N(\delta\hat{\theta}_o, \delta\sigma_o^2)]. \quad (3.3.1)$$

Applicando l'equazione (3.2), si ha:

$$KL_\delta(\hat{\theta}_o, \hat{\theta}_r; \delta) = \log\left(\frac{\sqrt{\delta}\sigma_o}{\sigma_r}\right) + \frac{\sigma_r^2 + (\hat{\theta}_r - \delta\hat{\theta}_o)^2}{2\delta\sigma_o^2} - \frac{1}{2}. \quad (3.3.2)$$

Introducendo, come nel Capitolo 2, la notazione standardizzata $d = \hat{\theta}_r/\hat{\theta}_o$ e $c = \sigma_o^2/\sigma_r^2$, si ha, dopo alcuni passaggi algebrici, che:

$$KL_\delta(\hat{\theta}_o, \hat{\theta}_r; \delta) = \frac{1}{2} \left[\log(\delta c) + \frac{1}{\delta c} + \frac{(\delta - d)^2}{\delta} z_o^2 - 1 \right]. \quad (3.3.3)$$

Per calibrare δ secondo il criterio appena introdotto, è sufficiente minimizzare, all'interno del dominio $(0,1)$, la (3.3.1), rispetto a δ . Derivando, si può ottenere che:

$$\frac{d}{d\delta} KL_\delta(\hat{\theta}_o, \hat{\theta}_r; \delta) = \frac{1}{2\delta^2} \left[\delta^2 z_o^2 + \delta - \frac{1}{c} - d^2 z_o^2 \right] \quad (3.4)$$

Moltiplicando per $2\delta^2$ e ponendo l'espressione uguale a 0, si ottiene la seguente equazione di stazionarietà:

$$\varphi(\delta) \stackrel{\text{def}}{=} \delta^2 z_o^2 + \delta - \frac{1}{c} - d^2 z_o^2 = 0 \quad (3.5)$$

Scartando pertanto la radice negativa, essendo questa fuori dal dominio di interesse, si ottiene:

$$\delta_{KL}^* = \frac{-1 + \sqrt{1 + 4z_o^2 \left(\frac{1}{c} + d^2 z_o^2\right)}}{2z_o^2} \quad (3.6)$$




Figura 11: KL_δ come funzione di δ per diversi valori di z_o e d , fissato $c = 1$. Il punto rosso e la linea tratteggiata indicano δ_{KL}^*

Come visibile nella Figura 11, δ_{KL}^* sembrerebbe essere crescente rispetto a z_o e a d , oltre che punto di minimo per KL_δ . Per verificare che la soluzione appena calcolata sia effettivamente un punto di minimo locale, è sufficiente valutare la derivata seconda nel punto:

$$\frac{d^2}{d\delta^2} KL_\delta(\hat{\theta}_o, \hat{\theta}_r; \delta) = \frac{1}{2\delta^3} [\varphi'(\delta)\delta - \varphi(\delta)] \quad (3.7)$$

Valutando in $\delta = \delta_{KL}^*$, dove, essendo per costruzione $\delta_{KL}^* > 0$ e $\varphi(\delta_{KL}^*) = 0$, si ha:

$$\frac{\varphi'(\delta_{KL}^*)}{2\delta_{KL}^{*2}} = \frac{2\delta_{KL}^* z_o^2 + 1}{2\delta_{KL}^{*2}} > 0 \quad (3.8)$$

Segue che KL_δ è convessa in δ_{KL}^* e questo risulta essere punto di minimo locale. Inoltre, dovendoci limitare al dominio $[0,1]$ e vista la monotonia di KL_δ , definiamo la stima KL come:

$$\hat{\delta}_{KL} = \min\{1, \max\{0, \delta_{KL}^*\}\} \quad (3.9)$$

Si può inoltre dimostrare come δ_{KL}^* sia crescente rispetto a d , supposto $d > 0$, ossia qualora vi sia concordanza di segno tra originale e replica. Infatti, fissati z_o e c , si ha:

$$\frac{\partial}{\partial d} \delta_{KL}^*(z_o, d, c) = \frac{2z_o^2}{\sqrt{1 + 4z_o^2 \left(\frac{1}{c} + d^2 z_o^2\right)}} d > 0 \quad (3.10)$$




Figura 12: $\hat{\delta}_{KL}$ come funzione di d per diversi valori di z_o , fissato $c = 1$

Infine, si può dimostrare che δ_{KL}^* è decrescente rispetto a c . Infatti, fissati z_o e d , si ha:

$$\frac{\partial}{\partial c} \delta_{KL}^*(z_o, d, c) = -\frac{2}{c^2 \sqrt{1 + 4z_o^2 \left(\frac{1}{c} + d^2 z_o^2\right)}} < 0 \quad (3.11)$$

Entrambi i risultati, riportati graficamente nelle Figure 12 e 13, sono coerenti con quanto ci si potesse immaginare: al crescere della dimensione dello studio replicativo o al crescere della sua precisione, la quota di restringimento si avvicina al suo limite superiore 1.




Figura 13: $\hat{\delta}_{KL}$ come funzione di c per diversi valori di d , fissato $z_o = 1$

3.2.2 EMPIRICAL BAYES

Un ulteriore approccio per la calibrazione di δ è offerto dal paradigma *Empirical Bayes* (Robbins, 1956; Casella, 1985). Per comprendere a pieno questo paradigma, si assuma che δ sia una variabile aleatoria dotata di distribuzione a priori, nota come *hyper-prior*, che indicheremo con $p(\delta)$, e si consideri il seguente modello gerarchico:

$$\delta \sim p(\delta), \quad \theta \sim N(0, \delta \sigma_o^2), \quad \theta | \delta, \hat{\theta}_o \sim N(\delta \hat{\theta}_o, \delta \sigma_o^2), \quad \hat{\theta}_r | \theta \sim N(\theta, \sigma_r^2)$$

La distribuzione a posteriori $p(\delta | \hat{\theta}_r)$, per il teorema di Bayes, è dunque:

$$p(\delta | \hat{\theta}_r) \propto p(\delta) f(\hat{\theta}_r | \delta) \quad (3.12)$$

dove $f(\hat{\theta}_r | \delta)$ è la verosimiglianza marginale, ottenibile integrando su θ come segue:

$$f(\hat{\theta}_r|\delta) = \int f(\hat{\theta}_r|\theta)f(\theta|\delta)d\theta$$

Essendo quest'ultimo un integrale di una convoluzione di normali, si può dimostrare che:

$$\hat{\theta}_r|\delta \sim N(\delta\hat{\theta}_o, \sigma_r^2 + \delta\sigma_o^2) \quad (3.13)$$

Assumendo che $p(\delta)$ sia costante sul supporto $(0,1)$, ossia $\delta \sim U(0,1) \equiv \text{Beta}(1,1)$, la (3.12) diviene:

$$p(\delta|\hat{\theta}_r) \propto f(\hat{\theta}_r|\delta). \quad (3.14)$$

Pertanto, se volessimo sostituire δ con il suo massimo a posteriori, solitamente indicato con *MAP*, avremmo che questo coincide con il massimizzare la verosimiglianza marginale. Infatti, data la (3.14), si ha:

$$\delta_{EB}^* \stackrel{\text{def}}{=} \arg \max_{\delta \in (0,1)} p(\delta|\hat{\theta}_r) = \arg \max_{\delta \in (0,1)} f(\hat{\theta}_r|\delta). \quad (3.15)$$

La sostituzione dell'intera distribuzione a posteriori con la sua sola moda, calcolata sotto hyper-prior piatta, è nota in letteratura proprio come approccio *Empirical Bayes*. Si noti inoltre come questa soluzione equivalga a minimizzare

$$BF_{0;\delta}(\hat{\theta}_r; \delta) \stackrel{\text{def}}{=} \frac{f(\hat{\theta}_r|H_0)}{f(\hat{\theta}_r|H_\delta)},$$

il cui numeratore non dipende da δ . Nel nostro caso di studio, essendo nota la forma della verosimiglianza marginale $f(\hat{\theta}_r|\delta)$, partendo dalla (3.13), si ottiene, a meno di costanti additive indipendenti da δ , la seguente log-verosimiglianza ℓ :

$$\ell(\delta) \propto -\frac{1}{2} \log(1 + \delta c) - \frac{(d - \delta)^2}{2(1 + \delta c)} c z_o^2 \quad (3.16)$$

Ponendo $\ell'(\delta) = 0$ e dopo diverse operazioni algebriche, si ottiene la seguente equazione di stazionarietà:

$$\varphi(\delta) \stackrel{\text{def}}{=} z_o^2 c \delta^2 + (c + 2z_o^2)\delta + (1 - 2z_o^2 d - z_o^2 c d^2) = 0 \quad (3.17)$$

con soluzione reale, all'interno dello spazio parametrico di interesse, pari a:

$$\delta_{EB}^* = \frac{-c - 2z_o^2 + \sqrt{4z_o^4(dc + 1)^2 + c^2}}{2z_o^2 c} \quad (3.18)$$

Al fine di valutare se si tratta effettivamente di un punto di massimo è necessario valutare la derivata seconda di $\ell(\delta)$ nel punto. Essendo $\ell'(\delta) = -\varphi(\delta)/(1 + \delta c)^2$ si ha:

$$\frac{d^2}{d\delta^2} \ell(\delta) = \frac{-\varphi'(\delta)(1 + \delta c)^2 + 2c\varphi(\delta)(1 + \delta c)}{(1 + \delta c)^4} \quad (3.19)$$

Da cui abbiamo che δ_{EB}^* è massimo locale se e solo se:

$$\ell''(\delta_{EB}^*) = -\frac{\varphi'(\delta_{EB}^*)}{(1 + \delta_{EB}^* c)^2} < 0 \quad (3.20)$$




Figura 14: $\ell(\delta)$ come funzione di δ per diversi valori di z_0 e d , fissato $c = 1$. Il punto rosso e la linea tratteggiata indicano δ_{EB}^*

Inoltre, limitandoci al dominio $[0,1]$, definiamo la stima *Empirical Bayes* come:

$$\hat{\delta}_{EB} = \min\{1, \max\{0, \delta_{EB}^*\}\} \quad (3.22)$$

Come fatto in precedenza, è possibile studiare il comportamento della soluzione al variare dei parametri c e d . Come visibile nella Figura 14, $\hat{\delta}_{EB}$ sembrerebbe essere crescente rispetto a d . Infatti, si può dimostrare come δ_{EB}^* sia crescente rispetto a d , supposto $d > 0$, ossia qualora vi sia concordanza di segno tra originale e replica. Fissati z_0 e c , si ha:

$$\frac{\partial}{\partial d} \delta_{EB}^*(z_0, d, c) = \frac{2z_0^2(1 + cd)}{\sqrt{4z_0^4(dc + 1)^2 + c^2}} > 0 \quad (3.23)$$




Figura 15: $\hat{\delta}_{EB}$ come funzione di d per diversi valori di z_o , fissato $c = 1$

Infine, si può dimostrare che δ_{EB}^* è decrescente rispetto a c . Infatti, fissati z_o e d , dopo svariati passaggi algebrici, si ha:

$$\frac{\partial}{\partial c} \delta_{EB}^*(z_o, d, c) = \frac{1}{c^2} - \frac{2z_o^2(dc + 1)}{c^2 \sqrt{4z_o^4(dc + 1)^2 + c^2}} \quad (3.24)$$

Da cui:

$$\frac{\partial}{\partial c} \delta_{EB}^*(z_o, d, c) > 0 \leftrightarrow \sqrt{4z_o^4(dc + 1)^2 + c^2} > 2z_o^2(dc + 1) \quad (3.25)$$

Assumendo che $d > 0$, la disequazione (3.25) è verificata per ogni $c > 0$.

Entrambi i risultati, riportati graficamente nelle Figure 15 e 16, sono coerenti con quanto ci si potesse immaginare: al crescere della dimensione dello studio replicativo o al crescere della sua precisione, la quota di restringimento si avvicina al suo limite superiore 1.




Figura 16: $\hat{\delta}_{EB}$ come funzione di c per diversi valori di d , fissato $z_o = 1$

3.2.3 FULL BAYES

L'approccio più flessibile per calibrare δ consiste nel trattare il parametro non come un valore fisso, ma come una variabile aleatoria dotata di una distribuzione a priori $p(\delta)$, definita sul dominio $(0,1)$, e aggiornata alla luce dello studio replicato, al fine di ottenere l'intera distribuzione a posteriori $p(\delta|\hat{\theta}_r)$, anziché una sua sintesi puntuale, secondo un cosiddetto approccio “Full Bayes”.

Il supporto di δ suggerisce l'impiego della famiglia $\text{Beta}(\alpha, \beta)$, con $\alpha, \beta > 0$, come distribuzione a priori. Come riportato nella Figura 17, tale famiglia offre una notevole flessibilità di forma. La scelta $\alpha = \beta = 1$ corrisponde alla distribuzione uniforme $U(0,1)$, coerente con l'assunzione di non informatività, mentre valori di α e β diversi da 1 permettono di concentrare la prior attorno al valore atteso $a/(a + b)$.




Figura 17: Confronto tra possibili a priori per δ

Nella scelta degli iperparametri α e β , occorre tenere conto della natura sostanziale del parametro δ e di quanto discusso nel Capitolo 1 circa l'entità del fenomeno di inflazione dell'effetto negli studi originali. Sebbene tale fenomeno sia ben documentato e diffuso, la letteratura non suggerisce un'inflazione sistematicamente così marcata da giustificare una prior fortemente concentrata verso lo zero. È dunque preferibile una prior centrata su valori moderatamente elevati di δ , la quale rifletta un atteggiamento fiducioso verso l'evidenza originale, lasciando che sia l'evidenza replicativa, tramite l'aggiornamento bayesiano, a determinare l'entità dell'eventuale restringimento richiesto.

Il modello per il singolo studio, dati gli iperparametri (α, β) , è quindi:

$$\delta \sim p(\delta), \quad \theta \sim N(0, \delta \sigma_o^2), \quad \theta | \delta, \hat{\theta}_o \sim N(\delta \hat{\theta}_o, \delta \sigma_o^2), \quad \hat{\theta}_r | \theta \sim N(\theta, \sigma_r^2)$$

La specificazione precedente tratta (α, β) come fissati, identici per ciascuno studio del dataset. È tuttavia possibile arricchire il modello aggiungendo un ulteriore livello, assegnando anche agli iperparametri (α, β) una propria distribuzione a priori $p(\alpha, \beta)$, da aggiornare congiuntamente sull'intero insieme di studi disponibili. Tale estensione comporta, tuttavia, un costo computazionale maggiore, oltre che una difficoltà

interpretativa nell'analisi dei parametri stessi. Pertanto, si è deciso di mantenere la struttura precedente nelle applicazioni seguenti, in modo da semplificare la trattazione.

Infine, si noti come la a posteriori $p(\delta|\hat{\theta}_r)$ non sia disponibile in forma chiusa: la famiglia Beta non è coniugata rispetto alla verosimiglianza con forma Gaussiana. È pertanto necessario, al fine di stimare $p(\delta|\hat{\theta}_r)$, ricorrere a metodi di approssimazione numerica, come ad esempio i metodi *Markov Chain Monte Carlo* e *Variational Inference*.

3.3 APPLICAZIONE PRATICA

I diversi metodi sviluppati nei paragrafi precedenti vengono ora applicati all'intero dataset *RProjects*, già impiegato nel Capitolo 2. Questo permette non soltanto di caratterizzare la distribuzione del parametro di restringimento δ sull'insieme degli studi disponibili, ma anche di verificare empiricamente la coerenza tra i diversi criteri di calibrazione, e di collocare il nuovo approccio nel quadro dei metodi bayesiani già delineato nel Capitolo 2.

3.3.1 CALIBRAZIONE KL E EMPIRICAL BAYES

Seguendo l'ordine di introduzione, si è deciso dapprima di calcolare $\hat{\delta}_{KL}$ e $\hat{\delta}_{EB}$ sull'intero dataset, al fine di confrontare le due calibrazioni puntuali.

Come visibile dalla Figura 18, i due metodi risultano in generale concordi, senza sostanziali differenze nella stima del parametro δ per la maggioranza degli studi. Si osservi tuttavia come la totalità dei punti si collochi al di sotto della retta $\hat{\delta}_{EB} = \hat{\delta}_{KL}$, sicché vale sistematicamente la relazione $\hat{\delta}_{EB} \leq \hat{\delta}_{KL}$. Segue che, a parità di dati, il criterio *Empirical Bayes* tende a restituire un grado di restringimento più marcato rispetto al criterio basato sulla divergenza di *Kullback-Leibler*.

Questo scostamento risulta particolarmente evidente in corrispondenza della fascia inferiore del grafico, dove si osserva un ampio insieme di studi con $\hat{\delta}_{EB} = 0$ a fronte di valori di $\hat{\delta}_{KL} > 0$. Queste osservazioni corrispondono ai casi in cui lo studio replicativo produce una stima di segno opposto rispetto a quella originale ($d < 0$). In tali circostanze, i due criteri rispondono in modo qualitativamente diverso: $\hat{\delta}_{KL}$ non è sensibile all'inversione di segno, in quanto la sua formula di stima dipende da d unicamente attraverso il termine

$d^2 z_0^2$, restituendo pertanto una stima calibrata sul valore assoluto di d ; $\hat{\delta}_{EB}$, al contrario, ne tiene esplicitamente conto, collocandosi in questi casi al bordo inferiore $\hat{\delta}_{EB} = 0$.




Figura 18: Confronto tra $\hat{\delta}_{KL}$ e $\hat{\delta}_{EB}$, calcolati sul dataset *RProjects*. La linea rossa tratteggiata indica la retta $\hat{\delta}_{EB} = \hat{\delta}_{KL}$

Come visibile nella Figura 19, la distribuzione di $\hat{\delta}_{EB}$ presenta un picco marcato in prossimità di 0, coerentemente con quanto appena osservato per i casi di discordanza di segno; $\hat{\delta}_{KL}$ mostra invece un picco più pronunciato in prossimità di 0.3. Entrambe le distribuzioni presentano comunque un'elevata concentrazione in corrispondenza di 0.9, a conferma della sostanziale, per quanto non perfetta, concordanza tra i due criteri nell'applicazione al dataset *RProjects*.

Da questo primo confronto emerge dunque un tratto distintivo del criterio *Empirical Bayes* rispetto al criterio *KL*, ossia la sua capacità di rispondere in modo qualitativamente corretto ai casi $d < 0$, collocandosi al bordo inferiore del dominio. Questo comportamento è auspicabile in quanto, un effetto originale, in presenza di una replica di segno opposto, non può essere ragionevolmente confermato in alcuna misura positiva. Infine, il criterio

Empirical Bayes risulta più scettico, nel senso di richiedere, a parità di dati, un maggior grado di restringimento dell'effetto originale.




Figura 19: Confronto tra le distribuzioni $\hat{\delta}_{KL}$ e $\hat{\delta}_{EB}$, calcolati sul dataset *RProjects*

3.3.2 APPLICAZIONE FULL BAYES

Si procede quindi all'applicazione del modello gerarchico introdotto in precedenza. Al fine di stimare la a posteriori $p(\delta|\hat{\theta}_r)$ si è deciso di utilizzare il pacchetto *cmdstanr* (Gabry *et al.*, 2024), che utilizza l'ausilio del software *Stan*, uno dei più utilizzati nell'ambito della statistica bayesiana per quanto riguarda la stima della distribuzione a posteriori tramite tecniche computazionali.

La Figura 20 riporta, per ciascuno dei quattro progetti (*Experimental Economics*, *Experimental Philosophy*, *Psychology*, *Social Sciences*), il *forest plot* delle mediane a posteriori di δ con relativo intervallo di credibilità al 95%, ottenuto sotto prior non informativa $U(0,1)$ e con gli studi ordinati per mediana crescente.

Il quadro che emerge è coerente in tutti e quattro i progetti: la distribuzione delle mediane copre pressoché l'intero intervallo (0,1). Inoltre, si osservi come l'ampiezza degli intervalli di credibilità sia eterogenea.

Tra i quattro progetti, *Experimental Philosophy* si distingue per una concentrazione relativamente maggiore di studi nella porzione superiore della distribuzione, suggerendo, con le dovute cautele derivanti dalla ridotta numerosità, un pattern di replicabilità più favorevole rispetto agli altri progetti.




Figura 20: Forest plot della mediana a posteriori di δ e relativo IC 95%, con prior $U(0,1)$, per progetto di replicazione

Le Figure 21a e 21b riportano, con analoga struttura, il confronto tra le quattro prior in termini di ampiezza dell'intervallo di credibilità al 95%, la misura di incertezza a posteriori. Il risultato più rilevante emerso nel confronto delle quattro prior (Figure 21a e 21b) è la sistematica minore ampiezza degli intervalli prodotti dalle prior Beta(2,5) e Beta(5,2). Nonostante ciò, si è scelto comunque di procedere all'utilizzo di una prior Beta(5,2). Tale scelta è motivata da una considerazione di coerenza teorica riguardo al grado di scetticismo che si decide di introdurre a priori. Si tenga conto però che tale scelta comporta, una

posteriori sistematicamente spostata verso valori di δ più elevati rispetto a una prior non informativa.




Figure 21a e 21b: *Boxplot* dell'ampiezza di IC per la mediana di δ al 95%, per prior e per progetto

Infine, adottata come a priori una Beta(5,2), si è scelto di visualizzare il meccanismo di stima bayesiano su alcuni studi di riferimento, selezionati da Consonni e Egidi (2025). Come visibile nella Figura 22, il meccanismo di ricalibrazione produce, per ciascuno studio, una prior H_δ (curva verde) intermedia tra la distribuzione originale non ristretta e l'ipotesi nulla e la a posteriori di θ (area verde chiaro). Quest'ultima si colloca conseguentemente in una posizione di compromesso tra le due fonti di informazione.




Figura 22: Distribuzioni posteriori di θ per gli studi selezionati. L'area verde rappresenta la densità a posteriori. La linea blu tratteggiata rappresenta la prior ricalibrata, mentre la linea rossa continua rappresenta la distribuzione associata alla replica

In particolare, i casi di Aviezer, Gneezy e Pyc presentano tre curve (prior ricalibrata, verosimiglianza della replica, posteriori) quasi perfettamente sovrapposte: si tratta di studi in cui l'evidenza originale, opportunamente ristretta, risulta già pienamente concorde con la replica, segno di uno shrinkage moderato ma efficace. I casi di Hauser, Janssen e Kovacs mostrano invece un disallineamento più marcato tra prior ricalibrata e verosimiglianza della replica, con la a posteriori che si colloca in posizione intermedia.

Il caso di Nurmsoo e Bloom (Figura 23), che a differenza dei precedenti presenta un valore di $d < 0$, evidenzia in modo particolarmente netto le conseguenze del *replication paradox*: la verosimiglianza della replica (rossa) è centrata su valori negativi, mentre la prior ricalibrata (blu), per costruzione vincolata a $\delta \in [0,1]$, non può che collocarsi su valori non negativi, nel caso specifico, prossima allo zero. La a posteriori risultante si posiziona in una regione di compromesso che non rispecchia adeguatamente né l'una né l'altra fonte di informazione, illustrando visivamente un limite strutturale: il modello non dispone, in

questa parametrizzazione, di alcun meccanismo per rappresentare esplicitamente l'inversione di segno, se non collassando verso l'ipotesi di nullità dell'effetto.




Figura 23: Distribuzione a posteriori di θ per lo studio di Nurmsoo e Bloom. L'area verde rappresenta la densità della a posteriori. La linea blu tratteggiata rappresenta la prior ricalibrata, mentre la linea rossa continua rappresenta la distribuzione associata alla replica

3.3.3 CONFRONTO TRA I METODI

Al fine di comparare, seppur in maniera approssimativa, le stime puntuali con il metodo *Full Bayes*, si è deciso di riportare il confronto tra media a posteriori $E[\delta|\hat{\theta}_r]$, $\hat{\delta}_{KL}$ e $\hat{\delta}_{EB}$, per diverse a priori. Emerge chiaramente come, in tutti i confronti, la nube di punti si collochi sistematicamente al di sopra della bisettrice per valori di $\hat{\delta}$ inferiori alla media a priori, per poi avvicinarsi progressivamente alla diagonale in corrispondenza di valori prossimi a tale media e, infine, disporsi al di sotto di essa per i valori più elevati. Tale andamento è coerente con il fenomeno di leva indotto dall'informazione a priori: la stima a posteriori viene infatti attratta verso il centro della distribuzione a priori. Di conseguenza, per valori di $\hat{\delta}$ prossimi alla media a priori, le stime ottenute mediante i diversi approcci tendono a convergere, mentre per valori più distanti emergono differenze più marcate tra

la stima basata sui criteri *KL* ed *Empirical Bayes* e quella *Full Bayes*. Il fenomeno risulta particolarmente evidente al variare della distribuzione a priori.




Figura 24: Confronto tra $E[\delta|\hat{\theta}_r]$, $\hat{\delta}_{KL}$ e $\hat{\delta}_{EB}$, calcolati sul dataset *RProjects*, con a priori Beta(5,2). Le linee rosse tratteggiate indicano le rette $E[\delta|\hat{\theta}_r] = \hat{\delta}_{KL}$ e $E[\delta|\hat{\theta}_r] = \hat{\delta}_{EB}$

Nel caso della Beta(1,1), invece, pur essendo generalmente considerata un'a priori non informativa o debolmente informativa nel contesto considerato, essa non è completamente priva di effetto sulla stima: l'aggiornamento bayesiano risente comunque della distribuzione scelta e, in particolare, dello specifico centro della distribuzione, determinando una tendenza delle stime posteriori verso 0.5. Nel complesso, la maggiore concordanza tra i tre approcci in termini di stima puntuale si osserva proprio in corrispondenza della Beta(1,1). Ciò suggerisce che, quando l'informazione introdotta dall'a priori è più debole, le differenze tra i criteri *KL* ed *EB* e l'approccio *Full Bayes* risultano meno marcate, come prevedibile. Al contrario, quando l'a priori è concentrata attorno a valori specifici, l'effetto leva diventa più evidente e le differenze tra le procedure di stima possono risultare maggiori, soprattutto per valori di δ lontani dalla media a priori.

3.4 SOGLIA PER IL SUCCESSO REPLICATIVO

Al fine di utilizzare il metodo appena discusso per valutare il successo di una replicazione, è necessario individuare un valore soglia $\tilde{\delta}$ che consenta di definire una regola decisionale. Data l'interpretazione di δ come fattore di restringimento simultaneo della media e della varianza dell'effetto originale, una regola decisionale intuitiva è la seguente:

$$\hat{\delta} \geq \tilde{\delta}$$

Infatti, qualora $\hat{\delta} \geq \tilde{\delta}$, il fattore di restringimento stimato risulta sufficientemente elevato rispetto alla soglia prefissata, ossia l'informazione proveniente dallo studio originale mantiene un peso maggiore del valore soglia nella stima dell'effetto replicato e, pertanto, la replicazione viene classificata come un successo replicativo.

La scelta del valore soglia rappresenta ovviamente un elemento cruciale, poiché determina il livello di concordanza richiesto affinché una replicazione sia considerata di successo. Oltre ad una possibile individuazione di $\tilde{\delta}$ tramite una valutazione empirica, è possibile proporre un'interpretazione teorica del parametro, vista la sua interpretabilità.

In particolare, come già sottolineato in precedenza, la quantità δ può essere interpretata come il peso assegnato all'evidenza empirica dello studio originale rispetto all'informazione introdotta dalla prior scettica. Una scelta naturale della soglia è quindi:

$$\tilde{\delta} = \frac{1}{2}$$

che corrisponde al caso in cui la varianza della prior $N(0, \alpha\sigma_o^2)$ ha la stessa precisione dello studio originale. Tale valore implica che il contributo della verosimiglianza e quello della prior abbiano lo stesso peso nella combinazione a posteriori. In altre parole, per $\delta = 1/2$, l'informazione proveniente dallo studio originale e l'ipotesi scettica di assenza di effetto contribuiscono in egual misura alla stima finale.

Una soglia alternativa, maggiormente conservativa, può essere definita come:

$$\tilde{\delta} = \frac{2}{3},$$

implicando che l'evidenza dello studio originale abbia un peso due volte superiore rispetto alla componente scettica ($\alpha = 2$). Tale scelta richiede pertanto un livello maggiore di accordo tra studio originale e replica per di classificare la replicazione come successo.

La Tabella 4 riporta il confronto, in termini di numero assoluto e percentuale, dei successi di replicazione per i diversi approcci di calibrazione del parametro δ , considerando entrambe le soglie teoriche proposte.

Dall'analisi dei risultati emerge innanzitutto il comportamento atteso rispetto alla scelta della soglia: passando da 1/2 a 2/3, il numero di repliche classificate come successo diminuisce per tutti i metodi considerati.

Shrinkage Method			
Metodo	$\tilde{\delta}$	Successi	Percentuale
Calibrazione KL	1/2	81	57%
Calibrazione KL	2/3	60	42%
Empirical Bayes	1/2	71	49%
Empirical Bayes	2/3	54	38%
Full Bayes con prior Beta(1,1)	1/2	75	52%
Full Bayes con prior Beta(1,1)	2/3	43	30%
Full Bayes con prior Beta(2,5)	1/2	25	17%
Full Bayes con prior Beta(2,5)	2/3	7	5%
Full Bayes con prior Beta(5,2)	1/2	141	99%
Full Bayes con prior Beta(5,2)	2/3	85	59%

Tabella 4: Confronto successi replicativi per differenti metodi di calibrazione e diverse soglie

Gli approcci basati sulla calibrazione *KL* ed *Empirical Bayes* mostrano risultati relativamente vicini, con percentuali di successo comprese tra il 38% e il 57%, con la stima *Empirical Bayes* che risulta essere meno permissiva, coerentemente con quanto già visto in precedenza. Questi risultati sono molto simili a quelli ottenuti con gli altri metodi bayesiani analizzati nel capitolo 2.

Al contrario, nell'approccio *Full Bayes* emerge una forte dipendenza dalla specificazione della distribuzione a priori. In particolare, la prior Beta(5,2), conduce ad una classificazione del successo replicativo estremamente favorevole. Questo risultato non deve essere interpretato come una maggiore capacità predittiva del metodo, ma come una conseguenza diretta dell'informazione introdotta a priori. Al contrario, la prior Beta(2,5),

che assegna maggiore probabilità a valori ridotti del fattore di restringimento, produce una valutazione molto più conservativa. Nel complesso, questi risultati sottolineano l'importanza di un'analisi di sensibilità rispetto alla scelta della distribuzione a priori.

3.5 LIMITI DEL NUOVO APPROCCIO

Sebbene il fattore di restringimento δ fornisca una misura interpretabile del grado di accordo tra studio originale e replica, la struttura del modello introduce alcuni vincoli che ne limitano l'applicabilità in situazioni più generali.

Innanzitutto, la costruzione del modello impone strutturalmente che $\delta \in [0,1]$, data la sua relazione con il parametro α . Di conseguenza, il modello è in grado di rappresentare solo una riduzione dell'effetto originale, ma non un suo eventuale aumento, per quanto quest'ultima ipotesi sia di solito poco diffusa. Pertanto, repliche con livelli di amplificazione molto diversi possono risultare indistinguibili per il modello: una replica leggermente superiore all'originale e una con un effetto molto più elevato vengono entrambe trattate come casi di massima compatibilità ($\delta = 1$). Analogamente, il vincolo sul dominio non permette di trattare i casi in cui vi sia inversione del segno dell'effetto ($d < 0$), se non trattandoli come casi di minima compatibilità ($\delta = 0$).

Un'estensione apparentemente naturale sarebbe consentire valori di δ fuori dall'intervallo $[0,1]$, così da rappresentare amplificazioni o inversioni di segno. Tuttavia, ciò comprometterebbe l'interpretazione teorica del parametro. Infatti, nella formulazione *Reverse Bayes*:

$$\delta = \frac{\alpha}{\alpha + 1}$$

dove $\alpha \geq 0$ è il fattore di proporzionalità presente nella varianza della prior $N(0, \alpha\sigma_o^2)$. Valori $\delta > 1$ o $\delta < 0$ implicherebbero quindi un parametro $\alpha < 0$, privo di interpretazione. L'estensione del dominio slegherebbe pertanto δ dalla connessione teorica con la a priori centrata in 0.

Un ulteriore limite deriva dalla scelta di utilizzare un unico parametro δ per controllare simultaneamente la media e la varianza della prior ricalibrata. Tale scelta è una conseguenza naturale della struttura normale-normale coniugata e costituisce uno dei principali punti di forza del metodo, poiché garantisce interpretabilità e proprietà analitiche.

Tuttavia, essa impedisce di distinguere tra due possibili fonti di incertezza: la fiducia nella magnitudine dell'effetto originale e la fiducia nella sua precisione. Un modello con parametri separati per media e varianza consentirebbe maggiore flessibilità, al prezzo di una minore interpretabilità.

Inoltre, come molti approcci bayesiani, il metodo assume una distribuzione approssimativamente normale delle stime degli effetti. Tale ipotesi risulta ragionevole per il dataset considerato, ma potrebbe risultare meno adeguata in altri casi.

Infine, la formulazione proposta considera il confronto tra un unico studio originale e una singola replicazione. Tuttavia, è possibile che siano disponibili molteplici repliche dello stesso effetto. Il modello attuale non consente di integrare direttamente tale informazione.

3.6 POSSIBILI ESTENSIONI

Una prima possibile estensione riguarda l'aggiunzione di un livello nel modello gerarchico bayesiano: invece di fissare arbitrariamente i parametri (α, β) della distribuzione Beta, questi potrebbero essere stimati congiuntamente sull'insieme degli studi, permettendo alle singole stime di beneficiare dell'informazione condivisa.

La stessa struttura gerarchica potrebbe essere estesa al caso di repliche multiple, sostituendo la singola osservazione replicativa con un insieme di evidenze indipendenti. In questo modo sarebbe possibile ottenere una misura di concordanza complessiva basata sulla totalità delle informazioni disponibili.

Inoltre, per prendere in considerazione possibili violazioni dell'ipotesi di normalità, la verosimiglianza gaussiana potrebbe essere sostituita con una distribuzione differente. Tale modifica aumenterebbe la robustezza del modello, al costo di perdere parte della semplicità analitica propria della formulazione normale-normale, centrale per i metodi di calibrazione puntuale.

Infine, una possibile estensione applicativa del metodo riguarda l'impiego dell'approccio *Full Bayes* non già per stimare il grado di restringimento a partire da una replica osservata, bensì per generare repliche simulate a partire dalla sola informazione disponibile nello studio originale. Questa idea verrà sviluppata e applicata nel successivo capitolo.

CAPITOLO 4: REVERSE BAYES SHRINKAGE (RBS) PREDICTIVE REPLICATION

Una possibile estensione del metodo *Reverse Bayes Shrinkage (RBS)* introdotto nel capitolo precedente riguarda l'utilizzo del modello non più come strumento di valutazione di una replica già esistente, bensì come strumento di generazione di repliche simulate, sfruttando l'informazione contenuta nello studio originale e, quando disponibile, aggiornandola con l'informazione proveniente dalla replica osservata. Inoltre, questo strumento potrebbe fungere da “simulazione surrogata” di un test di laboratorio nei casi in cui non vi siano fondi disponibili o tempistiche sufficienti per la produzione di effettive repliche.

L'intuizione alla base di questa estensione consiste nell'impiegare uno strumento largamente diffuso nell'inferenza bayesiana: il *Posterior Predictive Check* (Box, 1980; Gelman *et al.*, 2014). Sebbene tale strumento sia tradizionalmente di tipo diagnostico, nel presente capitolo se ne propone un utilizzo come meccanismo generativo, capace di produrre repliche artificiali coerenti con quanto il modello ritiene plausibile. Pertanto, il metodo di generazione delle repliche è stato soprannominato come *Reverse Bayes Shrinkage based Predictive Replication (RBS-PR)*. Si dividerà questo metodo in due approcci, dapprima non utilizzando lo studio replicativo e infine utilizzandone le informazioni contenute, applicandoli infine ad alcuni studi selezionati del dataset *RProjects*.

4.1 APPROCCIO SENZA REPLICA

Il primo approccio considerato è quello in cui non si tiene conto della replica osservata $\hat{\theta}_r$, bensì unicamente dell'informazione contenuta nello studio originale e nella prior scelta per δ . L'idea è campionare dalla distribuzione predittiva a posteriori di $\tilde{\theta}$, nuova replica dell'effetto, dopo l'osservazione dello studio originale $\hat{\theta}_o$, marginalizzando rispetto a δ , ossia utilizzare la distribuzione

$$p(\tilde{\theta}|\hat{\theta}_o) = \int p(\theta|\hat{\theta}_o, \delta)p(\delta|\hat{\theta}_o)d\delta,$$

dove $p(\delta|\hat{\theta}_o)$ è la prior scelta per il parametro di restringimento e $\tilde{\theta}|\hat{\theta}_o, \delta \sim N(\delta\hat{\theta}_o, \delta\sigma_o^2)$ è la a posteriori generativa ottenuta dopo l'osservazione dello studio originale. Questo schema corrisponde esattamente a un *Posterior Predictive Check*: si genera un valore di $\tilde{\theta}$

marginalizzando l'incertezza su δ , esattamente come si farebbe per verificare la bontà di predizione del modello, prima ancora di osservare ulteriori dati (Gelman *et al.*, 2014).

Supponendo di poter generare n campioni da $p(\tilde{\theta}|\hat{\theta}_o)$, tali campioni possono essere interpretati come n repliche simulate. Questo meccanismo generativo è “gratuito”, in quanto non richiede l'effettiva conduzione di nuovi esperimenti, ma solamente l'applicazione del modello alla sola informazione dello studio originale. È bene osservare che questi campioni si discostano dallo studio originale seguendo la logica del restringimento *RBS*. Come osservabile nella Figura 25, dove $\delta \sim \text{Beta}(5,2)$, il metodo, applicato agli studi selezionati da Consonni e Egidi (2025), sembra produrre risultati plausibili per gli studi con d prossimo alla media a priori. Infatti, per i casi appena citati, le repliche simulate (linee azzurre) non si discostano più di tanto dalla effettiva replica, vista la poca variabilità della prior selezionata ($V[\delta] \approx 1/40$). Si noti però come le repliche simulate sono tutte pressoché centrate intorno $E[\delta] \cdot \hat{\theta}_o$ e non capaci di catturare grandi scostamenti nella stima dell'effetto tra originale e replica.




Figura 25: Confronto tra distribuzione della replica e simulazioni senza l'utilizzo della replica, con $p(\delta) = \text{Beta}(5,2)$, per alcuni studi selezionati. Le linee azzurre rappresentano le simulazioni a priori, mentre la linea rossa continua rappresenta la distribuzione associata alla replica

Risultati simili si ottengono con l'adozione di una prior non informativa $U(0,1)$, rappresentati nella Figura 26. In questo caso la variabilità a priori è sensibilmente maggiore ($V[\delta] = 1/12$), aiutando così a produrre delle repliche simulate più disperse, seppur comunque concentrate attorno a $E[\delta] \cdot \hat{\theta}_o$. Questo confronto tra le due prior mostra visivamente, senza necessità di alcun test formale, quanto la scelta della prior discussa nel capitolo precedente sia fondamentale per la corretta generazione di repliche simulate e di come una scelta differente, svincolata dal limite teorico $\delta \in [0,1]$, potrebbe produrre risultati ancor più soddisfacenti.




Figura 26: Confronto tra distribuzione della replica e simulazioni senza utilizzo della replica, con $p(\delta) = U(0,1)$. Le linee azzurre rappresentano le simulazioni a priori, mentre la linea rossa continua rappresenta la distribuzione associata alla replica

4.2 APPROCCIO CON REPLICA

Il secondo approccio tiene conto della replica osservata $\hat{\theta}_r$ attraverso un aggiornamento bayesiano. L'idea è campionare dalla distribuzione predittiva a posteriori dopo l'osservazione dello studio originale $\hat{\theta}_o$ e dello studio replicativo $\hat{\theta}_r$, marginalizzando rispetto a δ , ossia utilizzando la distribuzione

$$p(\tilde{\theta}|\hat{\theta}_o, \hat{\theta}_r) = \int p(\tilde{\theta}|\hat{\theta}_o, \hat{\theta}_r, \delta)p(\delta|\hat{\theta}_o, \hat{\theta}_r)d\delta,$$

dove $p(\delta|\hat{\theta}_r)$ è la a posteriori di δ , di forma non chiusa, e $\tilde{\theta}|\hat{\theta}_o, \hat{\theta}_r, \delta \sim N(\delta\hat{\theta}_o, \delta\sigma_o^2)$ è la a posteriori di $\tilde{\theta}$ dopo l'osservazione di entrambi gli studi. Questo schema è tipico dei *Posteriori Predictive Check* e dell'aggiornamento bayesiano (Rubin, 1984). Come nel caso precedente, i campioni generati possono essere interpretati come repliche simulate, questa volta condizionate anche sulla replica effettivamente osservata.

Nella Figura 27, dove $\delta \sim \text{Beta}(5,2)$, si osserva come, per effetto dell'aggiornamento bayesiano, vi sia ora un'aderenza sensibilmente maggiore tra le repliche simulate (linee verdi) e la distribuzione della replica osservata (linea rossa), rispetto a quanto visto nell'approccio precedente.




Figura 27: Confronto tra distribuzione della replica e simulazioni con l'utilizzo della replica, con $p(\delta) = \text{Beta}(5,2)$, per degli studi selezionati. Le linee verdi rappresentano le simulazioni a posteriori, mentre la linea rossa continua rappresenta la distribuzione associata alla replica.

Nella Figura 28, adottando una prior non informativa, le simulazioni tendono ad assomigliare ancor di più alla replica stessa, essendo la a posteriori guidata quasi interamente dalla replica osservata.

Il confronto complessivo tra le quattro figure (25-28) illustra dunque come l'intero meccanismo generativo del modello basato sul metodo *RBS* possa essere facilmente adoperato per la generazione di repliche puramente "teoriche", dapprima governate solo dalla struttura della prior e dallo studio originale e infine anche dalle repliche, attraverso semplici strumenti di inferenza bayesiana.




Figura 28: Confronto tra distribuzione della replica e simulazioni con l'utilizzo della replica, con $p(\delta) = U(0,1)$, per degli studi selezionati. Le linee verdi rappresentano le simulazioni a priori, mentre la linea rossa continua rappresenta la distribuzione associata alla replica

4.3 LIMITI E POSSIBILI ESTENSIONI

L'estensione discussa nel presente capitolo eredita tutti i limiti già discussi nel Capitolo 3 a proposito della calibrazione di δ , in particolare il vincolo strutturale $\delta \in [0,1]$, che impedisce al modello di generare repliche simulate corrispondenti a un'amplificazione dell'effetto originale ($d < 1$) o a un'inversione di segno ($d > 0$), qualunque sia la prior scelta. A ciò si aggiunge un limite specifico di questa estensione: le repliche generate vanno interpretate come simulazioni di possibili repliche, non come simulazioni complete di un nuovo esperimento con la propria incertezza campionaria. Inoltre, la scelta della a priori,

vista la ridotta varianza della famiglia Beta, risulta limitante nella produzione di repliche più distanti dallo studio originale.

Un possibile sviluppo futuro consiste nell'estendere il dominio della prior, come già accennato in precedenza, in modo da consentire al meccanismo generativo di produrre repliche simulate anche nei casi di amplificazione dell'effetto o di inversione di segno. Come già discusso, questa estensione comporterebbe la perdita del legame diretto con la costruzione *Reverse Bayes* e con la parametrizzazione in termini di varianza della prior originaria. Tuttavia, ai soli fini generativi, e non più di calibrazione teoricamente vincolata, tale perdita di interpretabilità potrebbe essere un costo accettabile a fronte di un meccanismo sostanzialmente più flessibile per produrre repliche simulate "gratuite", utilizzabili ad esempio in studi di potenza, analisi di sensibilità, o come termine di confronto per repliche future non ancora condotte. Un secondo sviluppo naturale, già anticipato, riguarda l'impiego di una prior gerarchica per gli iperparametri della Beta(a, b).

CONCLUSIONI

Il presente lavoro ha affrontato il tema della valutazione della replicabilità scientifica su più fronti: da un lato, una rassegna critica e comparata della letteratura sul tema e degli strumenti già disponibili, evidenziandone punti di forza, limiti strutturali e, soprattutto, i paradossi che possono emergere nell'applicazione pratica di ciascuno; dall'altro, lo sviluppo di un metodo originale, fondato su un principio di *Reverse Bayes* distinto da quelli finora proposti nella comunità statistica.

Il metodo sviluppato nei Capitoli 3 e 4 della tesi possiede, a mio avviso, un pregio che merita di essere sottolineato in chiusura: la sua interpretabilità. Mentre i *Bayes Factors*, per quanto rigorosi e ben fondati, restituiscono un'evidenza relativa, il parametro δ qui proposto si presta a una lettura diretta e intuitiva, anche per chi non ha dimestichezza con il linguaggio bayesiano. Infatti, δ è semplicemente la quota dell'effetto originale che i dati replicativi permettono di confermare. Un δ prossimo a 1 afferma, senza ambiguità, che lo studio originale è stato sostanzialmente confermato dalla replica; un δ prossimo allo 0 afferma invece, con altrettanta chiarezza, che solo un ridimensionamento quasi totale dell'effetto originale lo renderebbe compatibile con quanto osservato nella replica. Questa trasparenza interpretativa non è un dettaglio estetico: in un campo come quello della valutazione della replicabilità, che nasce proprio dall'esigenza di comunicare in modo chiaro e onesto l'affidabilità dei risultati scientifici, la possibilità di esprimere tale affidabilità come una quota continua e intuitiva, anziché come un rapporto di verosimiglianze da interpretare su una scala convenzionale, rappresenta un contributo che ritengo di reale valore pratico, oltre che teorico.

Non sono mancati, nel corso del lavoro, i limiti, discussi con la dovuta onestà nei paragrafi dedicati di entrambi i capitoli originali. Il vincolo necessario a preservare il legame teorico con la costruzione *Reverse Bayes* di partenza, impedisce al metodo di rappresentare adeguatamente i casi, pur minoritari ma non irrilevanti, di amplificazione dell'effetto o di inversione di segno tra originale e replica. La scelta della prior nell'approccio *Full Bayes*, come ampiamente mostrato dall'analisi di sensibilità condotta sul dataset *RProjects*, non è neutra rispetto ai risultati finali, e richiede una giustificazione esplicita teorica oppure empirica, che l'utente del metodo dovrà necessariamente fornire in ogni applicazione concreta. Infine, l'estensione generativa discussa nel Capitolo 4, per quanto suggestiva,

resta allo stato di proposta preliminare, la cui piena validazione richiederebbe un confronto sistematico con repliche future.

Proprio da questi limiti discendono, tuttavia, le direzioni di ricerca che ritengo più promettenti per il proseguimento di questo lavoro. In primo luogo, l'estensione a un modello pienamente gerarchico, in cui gli iperparametri della prior su δ non siano fissati a priori ma stimati congiuntamente sull'intero corpus di studi disponibili. In secondo luogo, l'incorporazione di repliche multiple per un medesimo effetto attraverso una naturale generalizzazione della verosimiglianza attualmente impiegata. In terzo luogo, l'esplorazione di parametrizzazioni alternative che consentano di superare il vincolo $\delta \in [0,1]$, senza rinunciare del tutto all'interpretabilità che ha costituito, in questo lavoro, il principale motivo di interesse per l'approccio proposto. Infine, e forse più ambiziosamente, l'impiego sistematico della componente generativa del Capitolo 4 come strumento di progettazione di nuovi studi replicativi, non più soltanto come lente per giudicare repliche già condotte, ma come guida per orientare la pianificazione della ricerca futura.

Se la crisi della replicabilità ha insegnato qualcosa alla comunità scientifica, è che la fiducia in un risultato non può essere un giudizio binario cristallizzato ma deve essere concepita come un processo continuo di aggiornamento alla luce di nuova evidenza. È in questo spirito che si colloca, mi auguro con un contributo non trascurabile, il lavoro qui presentato.

RINGRAZIAMENTI

Nella vita non ci sono molti momenti in cui è possibile fermarsi e ringraziare chi ci è stato accanto: per questo voglio approfittare di questo spazio per dedicare qualche riga alle persone che, in un modo o nell'altro, mi hanno accompagnato in questo percorso e oltre.

Un ringraziamento speciale va al mio relatore, il Professor Egidi, per questi mesi di grandissimo aiuto, non solo nella stesura della tesi, e per essere stato una costante fonte di ispirazione. La passione che è riuscito a trasmettere durante i suoi corsi è stata fondamentale per capire cosa voglia fare nel mio futuro. Sarei più che orgoglioso di poter lavorare con lei un giorno, o magari di risfidarla su un campo da calcio (se il ginocchio lo permetterà).

Ringrazio di cuore i miei nonni, per l'infinito affetto che mi hanno sempre dimostrato nonostante la lontananza. Ringrazio mia zia Paola, per tutto l'amore che sa dare e per il grande esempio che è, in questo, per me.

Ringrazio il mio amico Hattori Hanzo, per avermi aiutato in questi anni a diventare una versione migliore di me stesso, ad aprirmi di più e per essere stato un esempio in questo.

Ci tengo a ringraziare mia sorella Alessia: so che non è sempre stato facile, ma ti sono immensamente grato per tutti gli sforzi che hai fatto e continui a fare per starmi accanto, e per la fiducia che mi hai sempre dato. Ringrazio anche il mio futuro cognato Riccardo, per la gioia che porta sempre con sé e che ha portato nella vita di mia sorella.

Ringrazio la mia fidanzata, Sara, per tutte le notti, i giorni, gli incubi e i sogni che abbiamo condiviso a metà. Sei stata per me un porto sicuro nei momenti più difficili, e accanto a te sono cresciuto e sono diventato la persona che sono oggi. Non vedo l'ora di continuare a crescere insieme a te.

Infine, ringrazio i miei genitori, che mi hanno sempre sostenuto e senza i quali nulla di tutto questo sarebbe stato possibile. A mia mamma, per essere sempre stata un esempio di rettitudine e una fonte di ispirazione in ogni mio passo, dandomi forza anche quando pensavo di non averne più. A mio padre, che è sempre riuscito a dimostrarmi un amore immenso attraverso tanti piccoli gesti, antepoendo sempre il mio bene a ogni sua cosa.

Spero di riuscire, almeno in parte, a restituire l'affetto che ognuno di voi è riuscito a darmi. Grazie!

BIBLIOGRAFIA

- Aldhous, P. (2011) «Journal rejects studies contradicting precognition».
- Baker, M. (2016) «1,500 scientists lift the lid on reproducibility», *Nature*, 533(7604), pp. 452–454. Disponibile su: <https://doi.org/10.1038/533452a>.
- Barba, L.A. (2018) «Terminologies for Reproducible Research». arXiv. Disponibile su: <https://doi.org/10.48550/arXiv.1802.03311>.
- Begley, C.G. e Ellis, L.M. (2012) «Raise standards for preclinical cancer research», *Nature*, 483(7391), pp. 531–533. Disponibile su: <https://doi.org/10.1038/483531a>.
- Bem, D.J. (2011) «Feeling the future: Experimental evidence for anomalous retroactive influences on cognition and affect.», *Journal of Personality and Social Psychology*, 100(3), pp. 407–425. Disponibile su: <https://doi.org/10.1037/a0021524>.
- Benjamin, D.J. *et al.* (2017) «Redefine statistical significance», *Nature Human Behaviour*, 2(1), pp. 6–10. Disponibile su: <https://doi.org/10.1038/s41562-017-0189-z>.
- Bergman, R.G. e Danheiser, R.L. (2016) «Reproducibility in Chemical Research», *Angewandte Chemie International Edition*, 55(41), pp. 12548–12549. Disponibile su: <https://doi.org/10.1002/anie.201606591>.
- Bishop, C.M. (2006) *Pattern recognition and machine learning*. New York: Springer (Information science and statistics).
- Box, G.E.P. (1980) «Sampling and Bayes' Inference in Scientific Modelling and Robustness», *Journal of the Royal Statistical Society. Series A (General)*, 143(4), p. 383. Disponibile su: <https://doi.org/10.2307/2982063>.
- Bretz, F. e Westfall, P.H. (2014) «Multiplicity and replicability: two sides of the same coin», *Pharmaceutical Statistics*, 13(6), pp. 343–344. Disponibile su: <https://doi.org/10.1002/pst.1648>.
- Broman, K. *et al.* (2017) «Recommendations to Funding Agencies for Supporting Reproducible Research».
- Buckheit, J.B. e Donoho, D.L. (1995) «WaveLab and Reproducible Research», in A. Antoniadis e G. Oppenheim (a c. di) *Wavelets and Statistics*. New York, NY: Springer New York (Lecture Notes in Statistics), pp. 55–81. Disponibile su: https://doi.org/10.1007/978-1-4612-2544-7_5.
- Button, K.S. *et al.* (2013) «Power failure: why small sample size undermines the reliability of neuroscience», *Nature Reviews Neuroscience*, 14(5), pp. 365–376. Disponibile su: <https://doi.org/10.1038/nrn3475>.
- Camerer, C.F. *et al.* (2016) «Evaluating replicability of laboratory experiments in economics», *Science*, 351(6280), pp. 1433–1436. Disponibile su: <https://doi.org/10.1126/science.aaf0918>.

- Camerer, C.F. *et al.* (2018) «Evaluating the replicability of social science experiments in Nature and Science between 2010 and 2015», *Nature Human Behaviour*, 2(9), pp. 637–644. Disponibile su: <https://doi.org/10.1038/s41562-018-0399-z>.
- Casadevall, A. e Fang, F.C. (2010) «Reproducible Science», *Infection and Immunity*, 78(12), pp. 4972–4975. Disponibile su: <https://doi.org/10.1128/IAI.00908-10>.
- Casella, G. (1985) «An Introduction to Empirical Bayes Data Analysis», pp. 83–87.
- Claerbout, J.F. e Karrenbach, M. (1992) «Electronic documents give reproducible research a new meaning», *SEG Technical Program Expanded Abstracts 1992*. *SEG Technical Program Expanded Abstracts 1992*, Society of Exploration Geophysicists, pp. 601–604. Disponibile su: <https://doi.org/10.1190/1.1822162>.
- Consonni, G. e Egidi, L. (2025) «Assessing replication success via skeptical mixture priors», *TEST*, 34(4), pp. 1012–1035. Disponibile su: <https://doi.org/10.1007/s11749-025-00985-7>.
- Cova, F. *et al.* (2021) «Estimating the Reproducibility of Experimental Philosophy», *Review of Philosophy and Psychology*, 12(1), pp. 9–44. Disponibile su: <https://doi.org/10.1007/s13164-018-0400-9>.
- Crook, S.M., Davison, A.P. e Plesser, H.E. (2013) «Learning from the Past: Approaches for Reproducibility in Computational Neuroscience», in J.M. Bower (a c. di) *20 Years of Computational Neuroscience*. New York, NY: Springer New York, pp. 73–102. Disponibile su: https://doi.org/10.1007/978-1-4614-1424-7_4.
- Davison, A. (2012) «Automated Capture of Experiment Context for Easier Reproducibility in Computational Research», *Computing in Science & Engineering*, 14(4), pp. 48–56. Disponibile su: <https://doi.org/10.1109/MCSE.2012.41>.
- Drummond, C. (2009) «Replicability is not Reproducibility: Nor is it Good Science».
- Duval, S. e Tweedie, R. (2000) «A Nonparametric “Trim and Fill” Method of Accounting for Publication Bias in Meta-Analysis», *Journal of the American Statistical Association*, 95(449), pp. 89–98. Disponibile su: <https://doi.org/10.1080/01621459.2000.10473905>.
- Fanelli, D. (2010) «Do Pressures to Publish Increase Scientists’ Bias? An Empirical Support from US States Data», *PLoS ONE*. A cura di E. Scalas, 5(4), p. e10271. Disponibile su: <https://doi.org/10.1371/journal.pone.0010271>.
- Fanelli, D. (2012) «Negative results are disappearing from most disciplines and countries», *Scientometrics*, 90(3), pp. 891–904. Disponibile su: <https://doi.org/10.1007/s11192-011-0494-7>.
- Gabry, J. *et al.* (2024) «cmdstanr: R Interface to ‘CmdStan’_. R package version 0.8.0, <<https://mc-stan.org/cmdstanr/>>.»
- Garfield, E. (1996) «What is the Primordial Reference for the phrase “Publish or Perish”?»
- Gelman, A. *et al.* (2014) *Bayesian data analysis*. Third edition. Boca Raton: CRC Press, Taylor & Francis Group (Texts in statistical science).

- Gelman, A. e Carlin, J. (2014) «Beyond Power Calculations: Assessing Type S (Sign) and Type M (Magnitude) Errors», *Perspectives on Psychological Science*, 9(6), pp. 641–651. Disponibile su: <https://doi.org/10.1177/1745691614551642>.
- Gelman, A. e Loken, E. (2014) «The Statistical Crisis in Science», *American Scientist*, 102(6), p. 460. Disponibile su: <https://doi.org/10.1511/2014.111.460>.
- Gelman, A. e Stern, H. (2006) «The Difference Between “Significant” and “Not Significant” is not Itself Statistically Significant», *The American Statistician*, 60(4), pp. 328–331. Disponibile su: <https://doi.org/10.1198/000313006X152649>.
- Gigerenzer, G. (2004) «Mindless statistics», *The Journal of Socio-Economics*, 33(5), pp. 587–606. Disponibile su: <https://doi.org/10.1016/j.socec.2004.09.033>.
- Good, I.J. (1950) «Probability and the Weighing of Evidence».
- Goodman, S.N. (1992) «A comment on replication, *P* -values and evidence», *Statistics in Medicine*, 11(7), pp. 875–879. Disponibile su: <https://doi.org/10.1002/sim.4780110705>.
- Goodman, S.N. (1999) «Toward Evidence-Based Medical Statistics. 2: The Bayes Factor», *Annals of Internal Medicine*, 130(12), pp. 1005–1013. Disponibile su: <https://doi.org/10.7326/0003-4819-130-12-199906150-00019>.
- Goodman, S.N., Fanelli, D. e Ioannidis, J.P.A. (2016) «What does research reproducibility mean?», *Science Translational Medicine*, 8(341). Disponibile su: <https://doi.org/10.1126/scitranslmed.aaf5027>.
- Green, P.J. *et al.* (2015) «Bayesian computation: a summary of the current state, and samples backwards and forwards», *Statistics and Computing*, 25(4), pp. 835–862. Disponibile su: <https://doi.org/10.1007/s11222-015-9574-5>.
- Held, L. (2020) «A New Standard for the Analysis and Design of Replication Studies», *Journal of the Royal Statistical Society Series A: Statistics in Society*, 183(2), pp. 431–448. Disponibile su: <https://doi.org/10.1111/rssa.12493>.
- Held, L. *et al.* (2021) «Reverse-Bayes methods for evidence assessment and research synthesis», *Research Synthesis Methods*, 13(3), pp. 295–314. Disponibile su: <https://doi.org/10.1002/jrsm.1538>.
- Held, L., Micheloud, C. e Pawel, S. (2022) «The assessment of replication success based on relative effect size», *The Annals of Applied Statistics*, 16(2). Disponibile su: <https://doi.org/10.1214/21-AOAS1502>.
- Ioannidis, J.P.A. (2005) «Why Most Published Research Findings Are False», *PLoS Medicine*, 2(8), p. e124. Disponibile su: <https://doi.org/10.1371/journal.pmed.0020124>.
- Jeffreys, H. (1961) *Theory of probability*. (3rd ed.). Oxford: Oxford University Press, Clarendon Press.
- John, L.K., Loewenstein, G. e Prelec, D. (2012) «Measuring the Prevalence of Questionable Research Practices With Incentives for Truth Telling», *Psychological Science*, 23(5), pp. 524–532. Disponibile su: <https://doi.org/10.1177/0956797611430953>.

Johnson, V.E. *et al.* (2017) «On the Reproducibility of Psychological Science», *Journal of the American Statistical Association*, 112(517), pp. 1–10. Disponibile su: <https://doi.org/10.1080/01621459.2016.1240079>.

Kass, R.E. e Raftery, A.E. (1995) «Bayes Factors», *Journal of the American Statistical Association*, 90(430), pp. 773–795. Disponibile su: <https://doi.org/10.1080/01621459.1995.10476572>.

Kerr, N.L. (1998) «HARKing: Hypothesizing After the Results are Known», *Personality and Social Psychology Review*, 2(3), pp. 196–217. Disponibile su: https://doi.org/10.1207/s15327957pspr0203_4.

Kullback, S. e Leibler, R.A. (1951) «On Information and Sufficiency», *The Annals of Mathematical Statistics*, 22(1), pp. 79–86. Disponibile su: <https://doi.org/10.1214/aoms/1177729694>.

Kunda, Z. (1990) «The case for motivated reasoning.», *Psychological Bulletin*, 108(3), pp. 480–498. Disponibile su: <https://doi.org/10.1037/0033-2909.108.3.480>.

Laraway, S. *et al.* (2019) «An Overview of Scientific Reproducibility: Consideration of Relevant Issues for Behavior Science/Analysis», *Perspectives on Behavior Science*, 42(1), pp. 33–57. Disponibile su: <https://doi.org/10.1007/s40614-019-00193-3>.

Leek, J. *et al.* (2017) «Five ways to fix statistics».

Leek, J. e Peng, R. (2015) «Statistics: P values are just the tip of the iceberg.», *Nature*(520), p. 612.

Leek, J.T. e Jager, L.R. (2017) «Is Most Published Research Really False?», *Annual Review of Statistics and Its Application*, 4(1), pp. 109–122. Disponibile su: <https://doi.org/10.1146/annurev-statistics-060116-054104>.

Liberman, M. (2015) «Replicability vs. reproducibility - or is it the other way around?», *The Language Log* [Preprint].

Ly, A. *et al.* (2019) «Replication Bayes factors from evidence updating», *Behavior Research Methods*, 51(6), pp. 2498–2508. Disponibile su: <https://doi.org/10.3758/s13428-018-1092-x>.

Makel, M.C., Plucker, J.A. e Hegarty, B. (2012) «Replications in Psychology Research: How Often Do They Really Occur?», *Perspectives on Psychological Science*, 7(6), pp. 537–542. Disponibile su: <https://doi.org/10.1177/1745691612460688>.

Martin, G.N. e Clarke, R.M. (2017) «Are Psychology Journals Anti-replication? A Snapshot of Editorial Practices», *Frontiers in Psychology*, 8. Disponibile su: <https://doi.org/10.3389/fpsyg.2017.00523>.

McCloskey, D.N. e Ziliak, S.T. (2007) «Signifying nothing: reply to Hoover and Siegler», *Journal of Economic Methodology*, 15(1), pp. 39–55. Disponibile su: <https://doi.org/10.1080/13501780801913413>.

Morey, R.D. e Rouder, J.N. (2012) «BayesFactor: Computation of Bayes Factors for Common Designs». Disponibile su: <https://doi.org/10.32614/CRAN.package.BayesFactor>.

Muradchanian, J. *et al.* (2024) «Evaluating meta-analysis as a replication success measure», *PLOS ONE*. A cura di D. Purić, 19(12), p. e0308495. Disponibile su: <https://doi.org/10.1371/journal.pone.0308495>.

Nosek, B.A. *et al.* (2022) «Replicability, Robustness, and Reproducibility in Psychological Science».

Open Science Collaboration (2015) «Estimating the reproducibility of psychological science», *Science*, 349(6251), p. aac4716. Disponibile su: <https://doi.org/10.1126/science.aac4716>.

Papoulis, A. e Pillai, S.U. (2002) *Probability, random variables, and stochastic processes*. 4. ed., internat. ed. Boston: McGraw-Hill (McGraw-Hill series in electrical and computer engineering).

Patil, P., Peng, R.D. e Leek, J.T. (2016) «What Should Researchers Expect When They Replicate Studies? A Statistical View of Replicability in Psychological Science», *Perspectives on Psychological Science*, 11(4), pp. 539–544. Disponibile su: <https://doi.org/10.1177/1745691616646366>.

Pauli, F. (2015) «Hypotheses testing: is it good for science?»

Pawel, S. e Held, L. (2022) «The sceptical Bayes factor for the assessment of replication success», *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 84(3), pp. 879–911. Disponibile su: <https://doi.org/10.1111/rssb.12491>.

Peng, R.D., Dominici, F. e Zeger, S.L. (2006) «Reproducible Epidemiologic Research», *American Journal of Epidemiology*, 163(9), pp. 783–789. Disponibile su: <https://doi.org/10.1093/aje/kwj093>.

Psarakis, S. e Panaretos, J. (1990) «The folded t distribution», *Communications in Statistics - Theory and Methods*, 19(7), pp. 2717–2734. Disponibile su: <https://doi.org/10.1080/03610929008830342>.

Robbins, H. (1956) «An Empirical Bayes Approach to Statistics», *Proceedings of the Third Berkeley Symposium on Mathematical Statistics and Probability*. University of California Press, pp. 157–163.

Rosenthal, R. (1979) «The file drawer problem and tolerance for null results.», *Psychological Bulletin*, 86(3), pp. 638–641. Disponibile su: <https://doi.org/10.1037/0033-2909.86.3.638>.

Rouder, J.N. *et al.* (2009) «Bayesian t tests for accepting and rejecting the null hypothesis», *Psychonomic Bulletin & Review*, 16(2), pp. 225–237. Disponibile su: <https://doi.org/10.3758/PBR.16.2.225>.

Rubin, D.B. (1984) «Bayesianly Justifiable and Relevant Frequency Calculations for the Applied Statistician», *The Annals of Statistics*, 12(4). Disponibile su: <https://doi.org/10.1214/aos/1176346785>.

Rubin, M. (2017) «When Does HARKing Hurt? Identifying When Different Types of Undisclosed Post Hoc Hypothesizing Harm Scientific Progress», *Review of General Psychology*, 21(4), pp. 308–320. Disponibile su: <https://doi.org/10.1037/gpr0000128>.

Schwab, M., Karrenbach, N. e Claerbout, J. (2000) «Making scientific computations reproducible», *Computing in Science & Engineering*, 2(6), pp. 61–67. Disponibile su: <https://doi.org/10.1109/5992.881708>.

Senn, S. (2002) «LETTER TO THE EDITOR A comment on replication, p -values and evidence S.N.Goodman, *Statistics in Medicine* 1992; **11** :875-879», *Statistics in Medicine*, 21(16), pp. 2437–2444. Disponibile su: <https://doi.org/10.1002/sim.1072>.

Simkus, A. *et al.* (2025) «Statistical Perspectives on Reproducibility: Definitions and Challenges», *Journal of Statistical Theory and Practice*, 19(3), p. 40. Disponibile su: <https://doi.org/10.1007/s42519-025-00459-x>.

Simmons, J.P., Nelson, L.D. e Simonsohn, U. (2011) «False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant», *Psychological Science*, 22(11), pp. 1359–1366. Disponibile su: <https://doi.org/10.1177/0956797611417632>.

Simonsohn, U. (2015) «Small Telescopes: Detectability and the Evaluation of Replication Results», *Psychological Science*, 26(5), pp. 559–569. Disponibile su: <https://doi.org/10.1177/0956797614567341>.

Simonsohn, U., Nelson, L.D. e Simmons, J.P. (2014) «P-curve: a key to the file-drawer», *Journal of Experimental Psychology. General*, 143(2), pp. 534–547. Disponibile su: <https://doi.org/10.1037/a0033242>.

Stodden, V. (2015) «Reproducing Statistical Results», *Annual Review of Statistics and Its Application*, 2(1), pp. 1–19. Disponibile su: <https://doi.org/10.1146/annurev-statistics-010814-020127>.

Teixeira Da Silva, J.A. (2015) «Negative results: negative perceptions limit their potential for increasing reproducibility», *Journal of Negative Results in BioMedicine*, 14(1), p. 12. Disponibile su: <https://doi.org/10.1186/s12952-015-0033-9>.

Vasishth, S. e Gelman, A. (2017) «The statistical significance filter leads to overconfident expectations of replicability». arXiv. Disponibile su: <https://doi.org/10.48550/arXiv.1702.00556>.

Verhagen, J. e Wagenmakers, E.-J. (2014) «Bayesian tests to quantify the result of a replication attempt.», *Journal of Experimental Psychology: General*, 143(4), pp. 1457–1475. Disponibile su: <https://doi.org/10.1037/a0036731>.

Wagenmakers, E.-J. *et al.* (2008) «Bayesian Versus Frequentist Inference», in H. Hoijtink, I. Klugkist, e P.A. Boelen (a c. di) *Bayesian Evaluation of Informative Hypotheses*. New York, NY: Springer New York, pp. 181–207. Disponibile su: https://doi.org/10.1007/978-0-387-09612-4_9.

Wagenmakers, E.-J. *et al.* (2018) «Bayesian inference for psychology. Part II: Example applications with JASP», *Psychonomic Bulletin & Review*, 25(1), pp. 58–76. Disponibile su: <https://doi.org/10.3758/s13423-017-1323-7>.

Wasserstein, R.L. e Lazar, N.A. (2016) «The ASA Statement on p -Values: Context, Process, and Purpose», *The American Statistician*, 70(2), pp. 129–133. Disponibile su: <https://doi.org/10.1080/00031305.2016.1154108>.

Wasserstein, R.L., Schirm, A.L. e Lazar, N.A. (2019) «Moving to a World Beyond “ $p < 0.05$ ”», *The American Statistician*, 73(sup1), pp. 1–19. Disponibile su: <https://doi.org/10.1080/00031305.2019.1583913>.

Zellner, A. e Siow, A. (1980) «Posterior odds ratios for selected regression hypotheses», *Trabajos de Estadística Y de Investigación Operativa*, 31(1), pp. 585–603. Disponibile su: <https://doi.org/10.1007/BF02888369>.